POLITECHNIKA BIAŁOSTOCKA

WYDZIAŁ INFORMATYKI

PRACA DYPLOMOWA MAGISTERSKA

TEMAT: Badanie wydajności wybranych silników obliczeniowych do przetwarzania danych przestrzennych w metrycznych układach odniesienia 2D

WYKONAWCA: Patryk Wójtowicz

OPIEKUN PRACY DYPLOMOWEJ: dr inż. Tomasz Grześ

BIAŁYSTOK 2026 ROK

Subject of diploma thesis

Performance testing of selected computational engines for processing spatial data in 2D metric reference systems

SUMMARY

The dynamic growth of spatial data usage in information systems and machine learning applications has increased the importance of efficient spatial data processing. Modern analytical workflows often rely on various computational engines that differ significantly in terms of architecture, supported spatial models, indexing mechanisms, and execution environments. These differences have a direct impact on the performance of spatial operations, especially when processing large-scale datasets.

The aim of this thesis is to compare the performance and resource characteristics of selected computational engines used for spatial data processing in two-dimensional metric reference systems. The study focuses on commonly used spatial operations relevant to feature engineering in machine learning tasks, such as distance calculations, spatial filtering, and nearest-neighbor queries. The analysis includes relational database systems, analytical in-memory engines, programming libraries, NoSQL databases, and cloud-based data warehouses.

The research methodology is based on a series of controlled empirical experiments conducted on real spatial datasets. Wherever possible, spatial indexes were applied in order to reflect realistic usage scenarios. Performance measurements were carried out with consideration of execution conditions such as cache effects and differences between planar and geodetic computation models. The obtained results are analyzed comparatively to identify strengths, limitations, and practical applicability of each engine.

The findings of this work provide practical insights into the selection of spatial data processing technologies for machine learning pipelines and analytical systems. The thesis also discusses methodological limitations and outlines directions for further research in the field of high-performance spatial data processing.

Temat pracy dyplomowej

Badanie wydajności wybranych silników obliczeniowych do przetwarzania danych przestrzennych w metrycznych układach odniesienia 2D

STRESZCZENIE

Dynamiczny rozwój zastosowań danych przestrzennych w systemach informatycznych oraz w zadaniach uczenia maszynowego powoduje rosnące znaczenie wydajnego przetwarzania informacji geograficznych. Współczesne procesy analityczne wykorzystują różnorodne silniki obliczeniowe, które różnią się architekturą, obsługiwanymi modelami przestrzennymi, mechanizmami indeksowania oraz środowiskiem wykonawczym. Różnice te mają bezpośredni wpływ na wydajność realizacji operacji przestrzennych, szczególnie w przypadku dużych zbiorów danych.

Celem niniejszej pracy jest porównanie wydajności oraz właściwości wybranych silników obliczeniowych wykorzystywanych do przetwarzania danych przestrzennych w dwuwymiarowych metrycznych układach odniesienia. Analiza koncentruje się na typowych operacjach przestrzennych istotnych z punktu widzenia inżynierii cech w zadaniach uczenia maszynowego, takich jak obliczanie odległości, filtrowanie przestrzenne oraz wyszukiwanie najbliższych obiektów. Badaniami objęto relacyjne systemy bazodanowe, silniki analityczne typu in-memory (zorientowane na przetwarzanie danych w pamięci operacyjnej), biblioteki programistyczne, bazy NoSQL oraz chmurowe hurtownie danych.

Metodyka badań opiera się na serii kontrolowanych eksperymentów empirycznych przeprowadzonych na rzeczywistych zbiorach danych przestrzennych. W miarę możliwości zastosowano indeksy przestrzenne w celu odwzorowania realistycznych scenariuszy użytkowych. Pomiary wydajności realizowano z uwzględnieniem warunków wykonania, takich jak wpływ pamięci podręcznej (*cache*) oraz różnice pomiędzy planarnym i geodezyjnym modelem obliczeń. Uzyskane wyniki poddano analizie porównawczej, pozwalającej na identyfikację mocnych stron, ograniczeń oraz praktycznej użyteczności poszczególnych silników.

Wyniki pracy dostarczają praktycznych wskazówek dotyczących doboru technologii przetwarzania danych przestrzennych w systemach analitycznych oraz potokach uczenia maszynowego. W pracy omówiono również ograniczenia zastosowanej metodyki oraz wskazano możliwe kierunki dalszych badań w obszarze wysokowydajnego przetwarzania danych przestrzennych.

Spis treści

1. Wstęp....6
1.1 Cel i zakres pracy....7
1.2 Pytania badawcze....7
1.3 Tezy badawcze....7
1.4 Struktura pracy....8
2. Podstawy teoretyczne przetwarzania danych przestrzennych....9
2.1 Dane przestrzenne i ich reprezentacja....9
2.2 Układy odniesienia przestrzennego....11
2.2.1 Układy geograficzne....11
2.2.2 Układy metryczne (projekcyjne)....12
2.2.3 Porównanie układów odniesienia przestrzennego....13
2.3 Modele obliczeń przestrzennych....14
2.3.1 Model planarny (geometry)....14
2.3.2 Model geodezyjny (geography)....15
2.3.3 Porównanie modeli obliczeń przestrzennych....16
2.4 Indeksy przestrzenne....17
2.5 Analiza aktualnego stanu badań nad wydajnością silników przetwarzania danych przestrzennych....18
3. Charakterystyka analizowanych silników obliczeniowych....22
3.1 Relacyjne systemy bazodanowe – PostgreSQL z rozszerzeniem PostGIS....22
3.2 Silniki analityczne typu in-memory – DuckDB z rozszerzeniem Spatial....24
3.3 Środowiska programistyczne – Python (GeoPandas, Shapely, GEOS)....25
3.4 Silniki NoSQL – MongoDB....27
3.5 Hurtownie danych w chmurze – BigQuery GIS....29
3.6 Porównanie architektur analizowanych silników....30
4. Metodyka badań empirycznych....32
4.1 Cel i zakres badań empirycznych....32
4.2 Zbiory danych wykorzystane w badaniach....33
4.3 Środowisko badawcze i konfiguracja eksperymentów....34
4.4 Układy odniesienia przestrzennego i modele obliczeń....35
4.5 Indeksowanie danych przestrzennych....36
4.6 Scenariusze eksperymentów....37
4.6.1 Założenia ogólne eksperymentów....37
4.6.2 Założenia preprocessingu danych wejściowych....38
4.6.3 Eksperymenty odległościowe i najbliższego sąsiada (E1–E4)....39
4.6.4 Eksperymenty geometryczne i topologiczne (E5–E8)....39
4.6.5 Eksperymenty na obiektach liniowych (E9–E12)....40
4.6.6 Eksperymenty agregacyjne na siatkach heksagonalnych (E13–E16)....41
4.7 Podsumowanie metodyki badań empirycznych....42
5. Wyniki badań empirycznych....43
5.1 Organizacja i zasady prezentacji wyników....43

5.2 Preprocessing danych.....44
5.2.1 Wyniki pomiarów czasowych preprocessingu.....44
5.2.2 Obserwacje empiryczne preprocessingu.....50
5.3 Eksperymenty odległościowe (E1–E4).....52
5.3.1 Wyniki pomiarów czasowych (E1–E4).....52
5.3.2 Obserwacje empiryczne (E1–E4).....55
5.4 Eksperymenty geometryczne i topologiczne (E5–E8).....57
5.4.1 Wyniki pomiarów czasowych (E5–E8).....57
5.4.2 Obserwacje empiryczne (E5–E8).....61
5.5 Eksperymenty liniowe (E9–E12).....62
5.5.1. Wyniki pomiarów czasowych (E9–E12).....62
5.5.2. Obserwacje empiryczne (E9–E12).....66
5.6 Eksperymenty agregacyjne (E13–E16).....67
5.6.1. Wyniki pomiarów czasowych (E13–E16).....67
5.6.2. Obserwacje empiryczne (E13–E16).....71
5.7 Podsumowanie wyników badań empirycznych.....71
6. Wnioski końcowe i kierunki dalszych badań.....74
6.1 Wnioski dotyczące wydajności obliczeń przestrzennych.....74
6.2 Wnioski dotyczące modeli przestrzeni: geometry vs geography.....76
6.3 Wnioski dotyczące doboru silnika do zastosowań praktycznych.....77
6.4 Ograniczenia przeprowadzonych badań.....79
6.5 Kierunki dalszych badań.....80
Bibliografia.....82
Spis tabel.....85
Spis rysunków.....86

1. Wstęp

W ostatnich latach obserwuje się dynamiczny wzrost znaczenia danych przestrzennych w systemach informatycznych, analizach geograficznych oraz w zastosowaniach uczenia maszynowego. Informacje o położeniu obiektów, ich relacjach przestrzennych oraz odległościach stanowią istotne źródło wiedzy wykorzystywane m.in. w analizach lokalizacyjnych, systemach rekomendacyjnych, modelowaniu zjawisk przestrzennych czy inżynierii cech dla modeli predykcyjnych. Wraz ze wzrostem wolumenu danych oraz złożoności zapytań rośnie znaczenie wydajnego przetwarzania operacji przestrzennych.

Współczesne środowiska analityczne oferują szeroki wachlarz silników obliczeniowych umożliwiających pracę z danymi przestrzennymi. Obejmują one relacyjne systemy bazodanowe, silniki analityczne typu in-memory, biblioteki programistyczne, bazy NoSQL oraz chmurowe hurtownie danych. Silniki te różnią się między sobą architekturą, sposobem reprezentacji danych przestrzennych, obsługiwanymi modelami obliczeń, mechanizmami indeksowania oraz środowiskiem wykonawczym. Różnice te wpływają bezpośrednio na sposób realizacji operacji przestrzennych oraz ich charakterystyki wydajnościowe.

Istotnym zagadnieniem w kontekście porównań wydajnościowych jest również wybór układu odniesienia oraz modelu obliczeń przestrzennych. W praktyce spotyka się zarówno układy geograficzne, oparte na współrzędnych kątowych, jak i układy metryczne, w których obliczenia prowadzone są w jednostkach liniowych. Dodatkowo silniki obliczeniowe mogą realizować operacje w modelu planarnym lub geodezyjnym, co ma wpływ nie tylko na dokładność obliczeń, lecz także na ich koszt obliczeniowy. Zagadnienia te są szczególnie istotne w zadaniach, w których przetwarzanie danych przestrzennych stanowi element większego potoku analitycznego lub uczenia maszynowego.

Motywacją do podjęcia niniejszego tematu jest potrzeba uporządkowanego, empirycznego porównania możliwości i wydajności wybranych silników obliczeniowych w kontekście przetwarzania danych przestrzennych w dwuwymiarowych metrycznych układach odniesienia. W praktyce inżynierskiej decyzja o wyborze technologii często podejmowana jest na podstawie fragmentarycznych informacji, dokumentacji technicznej lub doświadczeń projektowych, bez jednoznacznych porównań opartych na spójnej metodyce badawczej.

1.1 Cel i zakres pracy

Celem pracy jest porównanie wydajności wybranych silników obliczeniowych stosowanych do przetwarzania danych przestrzennych w dwuwymiarowych metrycznych układach odniesienia (EPSG:2180) oraz w przypadkach, w których wynika to z ograniczeń technologicznych w geodezyjnym modelu danych przestrzennych (EPSG:4326). Analiza obejmuje typowe operacje przestrzenne wykorzystywane w zadaniach analitycznych oraz w inżynierii cech dla modeli uczenia maszynowego. Zakres pracy obejmuje zarówno analizę teoretyczną architektury i możliwości badanych silników, jak i empiryczne badania wydajności przeprowadzone na rzeczywistych zbiorach danych.

1.2 Pytania badawcze

W pracy sformułowano następujące pytania badawcze:

- jak model obliczeń przestrzennych oraz wybór układu odniesienia wpływają na czasy wykonania zapytań,
- w jaki sposób zastosowanie indeksów przestrzennych wpływa na wydajność wykonywanych operacji,
- jakie różnice występują w zakresie obsługiwanych operacji przestrzennych w analizowanych silnikach obliczeniowych,
- w jakim stopniu badane silniki nadają się do zastosowań związanych z inżynierią cech w zadaniach uczenia maszynowego.

1.3 Tezy badawcze

Na podstawie analizy literatury oraz wstępnych założeń sformułowano następujące tezy badawcze:

- silniki wykorzystujące planarny model obliczeń w metrycznych układach odniesienia umożliwiają realizację operacji przestrzennych z mniejszym kosztem obliczeniowym w typowych scenariuszach analitycznych niż rozwiązania oparte na modelu geodezyjnym,
- wydajność operacji przestrzennych istotnie zależy od architektury silnika obliczeniowego oraz zastosowanych mechanizmów indeksowania,

- dobór silnika obliczeniowego do przetwarzania danych przestrzennych jest istotnie uwarunkowany charakterem wykonywanych operacji, modelem obliczeń przestrzennych oraz środowiskiem wykonawczym, co wpływa na jego przydatność w określonych zastosowaniach analitycznych i zadaniach uczenia maszynowego.

1.4 Struktura pracy

Praca składa się z sześciu rozdziałów. W rozdziale drugim przedstawiono podstawy teoretyczne przetwarzania danych przestrzennych, obejmujące modele danych i obliczeń przestrzennych, układy odniesienia przestrzennego, mechanizmy indeksowania oraz analizę aktualnego stanu badań nad wydajnością silników przetwarzania danych przestrzennych.

Rozdział trzeci zawiera charakterystykę analizowanych silników obliczeniowych oraz porównanie ich architektur. W rozdziale czwartym omówiono metodykę badań empirycznych, zastosowane zbiory danych oraz założenia eksperymentów. Rozdział piąty prezentuje wyniki badań empirycznych wraz z obserwacjami empirycznymi. Pracę zamykają wnioski końcowe oraz wskazanie kierunków dalszych badań.

2. Podstawy teoretyczne przetwarzania danych przestrzennych

Niniejszy rozdział wprowadza podstawowe pojęcia oraz zagadnienia teoretyczne niezbędne do zrozumienia dalszej części pracy. Przedstawiono w nim kluczowe koncepcje związane z danymi przestrzennymi, modelami reprezentacji geometrii, układami odniesienia przestrzennego oraz operacjami wykorzystywanymi w analizach GIS. Omówione zagadnienia stanowią fundament metodologiczny dla eksperymentów empirycznych i analiz porównawczych zaprezentowanych w kolejnych rozdziałach.

2.1 Dane przestrzenne i ich reprezentacja

Dane przestrzenne stanowią szczególną kategorię danych, w której oprócz atrybutów opisowych kluczową rolę odgrywa informacja o położeniu obiektów w przestrzeni. W systemach informatycznych wykorzystywane są do opisu zjawisk geograficznych, infrastruktury technicznej oraz procesów zachodzących w przestrzeni. W kontekście analiz komputerowych dane przestrzenne łączą w sobie aspekty geometrii, topologii oraz semantyki, co odróżnia je od klasycznych danych tabelarycznych [1].

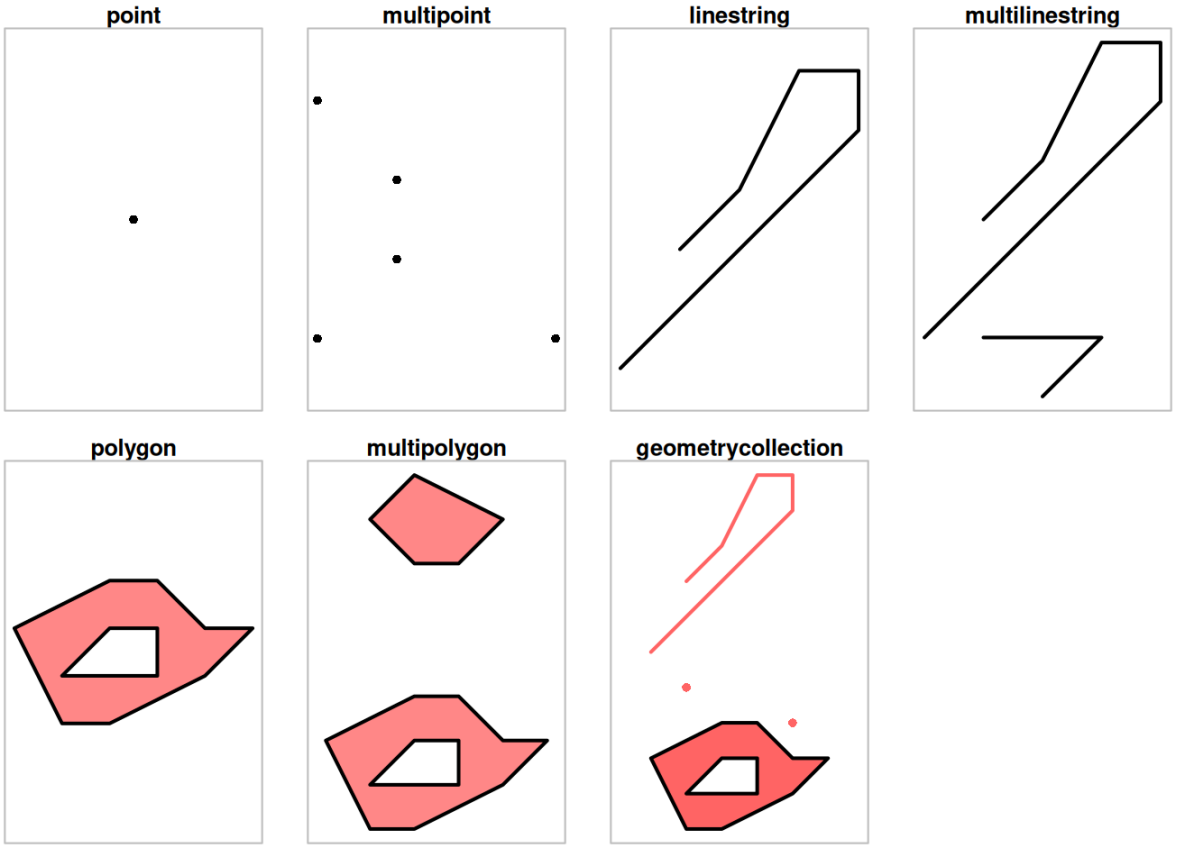
Podstawowym elementem danych przestrzennych jest geometria obiektu, która opisuje jego kształt i położenie. Najczęściej spotykane typy geometrii obejmują punkty, linie oraz wielokąty. Punkty wykorzystywane są do reprezentacji obiektów o pomijalnych rozmiarach, takich jak punkty użyteczności publicznej. Linie służą do opisu obiektów o charakterze liniowym, na przykład dróg, natomiast wielokąty wykorzystywane są do reprezentacji obszarów, takich jak jednostki administracyjne [2].

Tabela 2.1 Podstawowe typy geometrii przestrzennej i ich zastosowania

Typ geometrii (PL / EN)	**Charakterystyka**	**Przykłady zastosowań**
Punkt (Point)	Obiekt o pomijalnych rozmiarach, opisany pojedynczą parą współrzędnych	POI (punkty użyteczności z ang. Points Of Interest), lokalizacje zdarzeń, obiekty punktowe
Linia (Line - LineString)	Obiekt liniowy opisany sekwencją połączonych punktów	sieci drogowe, sieci hydrograficzne (rzeki), analizy dostępności
Wielokąt/Obszar (Polygon/Area)	Obszar zamknięty opisany granicą	jednostki administracyjne, agregacje przestrzenne

Źródło: opracowanie własne

Źródło: R Spatial Community [3]



Rys. 2.1 Podstawowe typy geometrii przestrzennej

Oprócz geometrii istotnym aspektem danych przestrzennych są relacje przestrzenne pomiędzy obiektami. Mogą one obejmować relacje topologiczne, takie jak zawieranie, przecinanie czy styczność, a także relacje metryczne, w szczególności odległości pomiędzy obiektami. Operacje wykorzystujące relacje przestrzenne stanowią podstawę zapytań przestrzennych realizowanych w systemach bazodanowych i silnikach analitycznych.

W praktycznych zastosowaniach dane przestrzenne przechowywane są w różnych formatach i strukturach danych. W systemach bazodanowych oraz bibliotekach programistycznych powszechnie stosowane są reprezentacje zgodne ze standardami organizacji Open Geospatial Consortium [2], które definiują zarówno typy geometrii, jak i zestaw operacji przestrzennych możliwych do wykonania na tych obiektach. Standaryzacja ta umożliwia interoperacyjność pomiędzy różnymi narzędziami oraz porównywanie ich funkcjonalności.

W kontekście przetwarzania danych przestrzennych istotne znaczenie ma również sposób powiązania geometrii z danymi opisowymi. Najczęściej geometria stanowi jeden z atrybutów rekordu danych, obok cech niemających charakteru przestrzennego. Taki model

umożliwia łączenie klasycznych operacji relacyjnych z operacjami przestrzennymi, co ma kluczowe znaczenie w analizach wielowymiarowych oraz w procesach inżynierii cech na potrzeby modeli uczenia maszynowego. Przykładami takich cech mogą być odległości do wybranych obiektów referencyjnych, zagęszczenie punktów w określonym promieniu czy przynależność obiektu do określonej jednostki przestrzennej.

2.2 Układy odniesienia przestrzennego

Układ odniesienia przestrzennego (*Coordinate Reference System*, CRS [4]) definiuje sposób odwzorowania położenia obiektów w przestrzeni za pomocą współrzędnych liczbowych. W praktyce wybór układu odniesienia ma kluczowe znaczenie zarówno dla poprawności interpretacji danych, jak i dla charakteru wykonywanych obliczeń przestrzennych. Układ odniesienia determinuje jednostki miary, zakres dopuszczalnych operacji oraz sposób interpretacji odległości, powierzchni i relacji przestrzennych.

Należy odróżnić układ odniesienia (CRS), który definiuje sposób zapisu współrzędnych, od modelu obliczeń przestrzennych, który określa, czy operacje wykonywane są w przestrzeni planarnej czy geodezyjnej. Przykładowo EPSG:4326 opisuje układ współrzędnych geograficznych, natomiast metryczne obliczenia w tym układzie mogą być realizowane poprzez model geodezyjny (np. typ geography) lub przez zastosowanie transformacji do układu metrycznego. Zagadnienie modeli obliczeń i ich konsekwencji omówiono w podrozdziale 2.3.

W systemach przetwarzania danych przestrzennych powszechnie stosowane są dwa główne rodzaje układów odniesienia: układy geograficzne, oparte na współrzędnych kątowych, oraz układy projekcyjne (metryczne), w których współrzędne wyrażone są w jednostkach liniowych. Różnice pomiędzy tymi podejściami mają istotne konsekwencje zarówno z punktu widzenia dokładności obliczeń przestrzennych, kosztu obliczeniowego realizowanych operacji, jak i dostępności określonych funkcji analitycznych.

2.2.1 Układy geograficzne

Układy geograficzne opisują położenie obiektów za pomocą szerokości i długości geograficznej, wyrażonych najczęściej w stopniach [4]. Najbardziej rozpowszechnionym układem tego typu jest układ oparty na systemie odniesienia przestrzennego WGS 84, powszechnie identyfikowany kodem EPSG:4326 [5]. Układ ten stanowi standard de facto w globalnych zbiorach danych, systemach nawigacyjnych oraz usługach mapowych.

W układach geograficznych współrzędne nie mają charakteru metrycznego, co oznacza, że odległości pomiędzy punktami nie mogą być bezpośrednio interpretowane jako wartości liniowe. Obliczenia metryczne wymagają uwzględnienia krzywizny Ziemi i realizowane są w oparciu o modele sferyczne lub elipsoidalne. W praktyce prowadzi to do zwiększenia złożoności obliczeń oraz ograniczenia dostępnych operacji w niektórych silnikach obliczeniowych.

Z uwagi na globalny charakter oraz jednoznaczność interpretacyjną układy geograficzne są często stosowane jako format wymiany danych pomiędzy systemami. Jednocześnie ich wykorzystanie w analizach wymagających intensywnych obliczeń przestrzennych może wiązać się z dodatkowymi kosztami obliczeniowymi, szczególnie w przypadku dużych zbiorów danych.

2.2.2 Układy metryczne (projekcyjne)

Układy metryczne, zwane również układami projekcyjnymi, odwzorowują powierzchnię Ziemi na płaszczyznę, umożliwiając wyrażenie współrzędnych w jednostkach liniowych, takich jak metry [4]. Dzięki temu możliwe jest bezpośrednie wykonywanie obliczeń odległości, powierzchni oraz relacji przestrzennych w sposób planarny.

W analizach lokalnych oraz regionalnych powszechnie stosowane są układy projekcyjne dostosowane do konkretnego obszaru geograficznego. W przypadku analiz prowadzonych na obszarze Polski szeroko wykorzystywany jest państwowy układ odniesienia PL-1992, identyfikowany kodem EPSG:2180 [6]. Układ ten minimalizuje zniekształcenia na obszarze kraju i umożliwia prowadzenie analiz metrycznych z wysoką precyzją.

Zastosowanie układów metrycznych jest szczególnie istotne w zadaniach, w których operacje przestrzenne wykonywane są wielokrotnie, na przykład podczas obliczania cech przestrzennych dla modeli uczenia maszynowego. Planarny charakter obliczeń pozwala w takich przypadkach na redukcję kosztu obliczeniowego w porównaniu do obliczeń realizowanych w modelu geodezyjnym.

2.2.3 Porównanie układów odniesienia przestrzennego

Tabela 2.2.3 Porównanie układów odniesienia przestrzennego

Cecha	Układ geograficzny	Układ metryczny
Typ współrzędnych	kątowe	liniowe
Jednostka miary	stopnie kątowe	metry
Model odniesienia	elipsoida / sfera	rzut płaszczyznowy elipsoidy (model planarny)
Charakter obliczeń	geodezyjny	planarny
Interpretacja miar geometrycznych	pośrednia, geodezyjna	bezpośrednia, metryczna
Zniekształcenia	zmienne w skali globalnej	minimalizowane lokalnie w obszarze obowiązywania układu
Przykładowy kod EPSG	EPSG:4326	EPSG:2180

Źródło: opracowanie własne

Źródło: OpenNews [7]



Rys. 2.2.3 Porównanie wizualizacji części obszaru Stanów Zjednoczonych w różnych układach odniesienia przestrzennego (EPSG:4326, EPSG:2163, EPSG:3857, EPSG:2955)

Rysunek 2.2 przedstawia porównanie wizualizacji części obszaru Stanów Zjednoczonych w różnych układach odniesienia przestrzennego, co ilustruje wpływ wyboru

układu współrzędnych na kształt i proporcje obiektów. Układ EPSG:4326 (WGS 84) jest układem geograficznym, w którym współrzędne wyrażone są w stopniach kątowych i nie posiadają bezpośredniej interpretacji metrycznej. Pozostałe układy (EPSG:2163, EPSG:3857 oraz EPSG:2955) są układami projekcyjnymi o charakterze metrycznym, w których współrzędne wyrażone są w jednostkach liniowych, jednak różnią się zakresem stosowalności oraz poziomem zniekształceń przestrzennych.

2.3 Modele obliczeń przestrzennych

Modele obliczeń przestrzennych określają sposób realizacji operacji na danych przestrzennych. W praktyce systemów GIS oraz silników obliczeniowych najczęściej wyróżnia się dwa podejścia: model planarny, oparty na geometrii euklidesowej, oraz model geodezyjny, który uwzględnia krzywiznę powierzchni Ziemi. Wybór modelu obliczeń ma bezpośredni wpływ na interpretację wyników analiz przestrzennych, zakres dostępnych operacji oraz ich koszt obliczeniowy.

Modele planarne sprzyjają efektywnej realizacji obliczeń przestrzennych na ograniczonym obszarze, gdzie przestrzeń może być traktowana jako płaska i wyrażona w jednostkach liniowych. Z kolei modele geodezyjne zapewniają poprawną interpretację wyników w skali regionalnej i globalnej, jednak wiąże się to z większą złożonością obliczeniową. Rozróżnienie pomiędzy tymi podejściami stanowi istotny element metodologii badań empirycznych przedstawionych w dalszej części pracy, umożliwiając świadome projektowanie eksperymentów z zachowaniem spójności i porównywalności wyników.

W kontekście narzędzi informatycznych modele obliczeń przestrzennych są często powiązane z typami danych określanymi jako geometry oraz geography. Choć nazewnictwo to wywodzi się z konkretnych implementacji systemowych, w niniejszej pracy terminy te odnoszą się do przyjętego modelu matematycznego obliczeń, a nie do konkretnego silnika obliczeniowego lub biblioteki programistycznej.

2.3.1 Model planarny (geometry)

Model planarny zakłada, że przestrzeń, w której wykonywane są obliczenia, ma charakter płaski. Obiekty przestrzenne reprezentowane są w układzie współrzędnych, w którym odległości oraz powierzchnie mogą być interpretowane bezpośrednio w jednostkach liniowych. Operacje przestrzenne realizowane w tym modelu opierają się na klasycznej geometrii euklidesowej [1,8].

Dzięki temu możliwe jest bezpośrednie obliczanie odległości, długości czy powierzchni bez konieczności stosowania złożonych algorytmów geodezyjnych. W praktyce przekłada się to na niższy koszt obliczeniowy oraz większą przewidywalność wyników w analizach lokalnych i regionalnych.

Model planarny jest powszechnie stosowany w zadaniach wymagających intensywnego przetwarzania danych przestrzennych, takich jak inżynieria cech w systemach uczenia maszynowego. Wielokrotne wykonywanie operacji odległościowych lub przestrzennych filtrów w tym modelu pozwala na osiągnięcie lepszej wydajności w porównaniu do obliczeń realizowanych w modelu geodezyjnym, przy zachowaniu wystarczającej dokładności dla analiz ograniczonych przestrzennie.

2.3.2 Model geodezyjny (geography)

Model geodezyjny uwzględnia krzywiznę powierzchni Ziemi i opiera się na obliczeniach prowadzonych na sferze lub elipsoidzie odniesienia. W tym podejściu współrzędne obiektów przestrzennych interpretowane są jako punkty na powierzchni globu, a obliczenia metryczne realizowane są z wykorzystaniem algorytmów geodezyjnych [1,8].

Zastosowanie modelu geodezyjnego jest niezbędne w analizach o charakterze globalnym lub międzykontynentalnym, gdzie zniekształcenia wynikające z odwzorowań płaskich mogłyby prowadzić do istotnych błędów. Jednocześnie realizacja operacji przestrzennych w tym modelu wiąże się z większym kosztem obliczeniowym oraz, w niektórych systemach, z ograniczoną dostępnością funkcji przestrzennych.

W praktyce silniki obliczeniowe różnią się stopniem wsparcia dla modelu geodezyjnego. Część operacji dostępnych w modelu planarnym może nie być zaimplementowana lub może działać w sposób ograniczony w przypadku obliczeń geodezyjnych. Różnice te mają istotne znaczenie w projektowaniu eksperymentów porównawczych oraz w interpretacji uzyskanych wyników.

2.3.3 Porównanie modeli obliczeń przestrzennych

Tabela 2.3.3 Operacje przestrzenne w modelach geometry i geography

Klasa operacji przestrzennych	geometry	geography
Relacje topologiczne (intersects, within)	✔	✔
Obliczenia odległościowe	✔	✔
Zapytania promieniowe (DWithin)	✔	ograniczone
Operacje buforowania	✔	ograniczone
Operacje agregacyjne (union, collect)	✔	ograniczone
Analizy najbliższego sąsiedztwa	✔	przybliżone
Operacje walidacji geometrii	✔	✖
Transformacje układów odniesienia (CRS)	✔	pośrednie

Źródło: opracowanie własne na podstawie standardów OGC (Open Geospatial Consortium) [2] oraz dokumentacji PostGIS [8]

Operacje oznaczone jako ograniczone są dostępne w modelu geography, jednak ich zakres funkcjonalny oraz sposób realizacji różnią się istotnie od analogicznych operacji w modelu geometry. Ograniczenia te wynikają z geodezyjnego charakteru obliczeń wykonywanych na powierzchni elipsoidy, co znacząco zwiększa złożoność obliczeniową operacji wymagających przetwarzania obszarów lub agregacji wielu obiektów przestrzennych.

W szczególności dotyczy to zapytań promieniowych, operacji buforowania oraz części operacji agregacyjnych. W modelu geography zapytania promieniowe są realizowane poprawnie pod względem semantycznym, jednak każdorazowo wymagają obliczeń geodezyjnych, co wpływa na ich wydajność i ogranicza możliwość skalowania do bardzo dużych zbiorów danych. Operacje buforowania oraz agregacji są dostępne w węższym zakresie niż w modelu geometry i w praktyce często prowadzą do stosowania obejść polegających na czasowej konwersji danych do modelu planarmego.

Określenie przybliżone odnosi się do operacji, które są dostępne w modelu geography, lecz nie wykorzystują pełnego, najbardziej dokładnego modelu obliczeń geodezyjnych. Przykładem są analizy najbliższego sąsiedztwa (KNN), w których porządkowanie obiektów według odległości realizowane jest z użyciem uproszczonej metryki sferycznej, a nie dokładniejszego modelu sferoidalnego.

W praktyce oznacza to, że wyniki takich operacji są poprawne z punktu widzenia logiki zapytania i użyteczne w analizach eksploracyjnych lub porównawczych, jednak mogą nie odpowiadać dokładnie wartościom uzyskiwanym przy zastosowaniu pełnych funkcji odległościowych opartych na elipsoidzie. Różnice te są zazwyczaj niewielkie, lecz istotne metodologicznie w kontekście precyzyjnych analiz metrycznych.

Operacje oznaczone jako pośrednie nie są realizowane bezpośrednio w modelu geography, lecz wymagają zastosowania dodatkowych etapów przetwarzania z wykorzystaniem modelu geometry. Dotyczy to w szczególności transformacji układów odniesienia, które są operacjami naturalnymi dla geometrii planarnych, lecz nie są bezpośrednio obsługiwane w modelu geography.

W praktyce standardowym podejściem jest wykonanie transformacji układu odniesienia na obiekcie typu geometry, a następnie ewentualna konwersja wyniku do typu geography. Takie podejście jest poprawne merytorycznie, jednak wprowadza dodatkowy krok w potoku przetwarzania danych oraz ogranicza elastyczność operacyjną modelu geography w złożonych analizach przestrzennych.

2.4 Indeksy przestrzenne

W analizach danych przestrzennych istotną rolę odgrywa sposób organizacji i wyszukiwania obiektów przestrzennych. W przeciwieństwie do danych niemających charakteru przestrzennego, dla których powszechnie stosowane są klasyczne struktury indeksowe, takie jak drzewa B (B-trees), dane przestrzenne wymagają wykorzystania wyspecjalizowanych mechanizmów indeksowania, uwzględniających ich wielowymiarowy charakter [9].

Indeksy przestrzenne umożliwiają efektywne ograniczenie liczby obiektów podlegających dalszym obliczeniom poprzez wstępne zawężenie obszaru przeszukiwania. Zamiast wykonywania operacji przestrzennych na całym zbiorze danych, analizowane są jedynie obiekty potencjalnie spełniające zadane kryteria przestrzenne, co ma kluczowe znaczenie dla wydajności zapytań realizowanych na dużych zbiorach danych.

W odróżnieniu od indeksów klasycznych, które porządkują dane wzdłuż jednego wymiaru, indeksy przestrzenne bazują na strukturach umożliwiających organizację danych w przestrzeni wielowymiarowej. Najczęściej wykorzystywane podejścia opierają się na hierarchicznym grupowaniu obiektów w prostokąty ograniczające, co pozwala na szybkie eliminowanie obszarów nieistotnych z punktu widzenia realizowanego zapytania.

Zastosowanie indeksów przestrzennych ma szczególne znaczenie w przypadku zapytań odległościowych, złączeń przestrzennych oraz operacji topologicznych, takich jak sprawdzanie przynależności obiektu do obszaru czy wyszukiwanie najbliższych sąsiadów [9]. Jednocześnie efektywność ich wykorzystania zależy od charakteru danych oraz rodzaju wykonywanych operacji — w praktyce indeksy przestrzenne są najbardziej opłacalne w przypadku dużych i względnie statycznych zbiorów danych, natomiast w scenariuszach obejmujących częste modyfikacje geometrii lub przetwarzanie danych w pamięci operacyjnej ich rola może mieć odmienny charakter.

Podsumowując, indeksy przestrzenne stanowią jeden z kluczowych elementów wpływających na wydajność obliczeń przestrzennych. Ich obecność lub brak, a także sposób ich wykorzystania, mogą mieć istotny wpływ na czas realizacji zapytań przestrzennych, co uzasadnia uwzględnienie tego zagadnienia w analizach wydajnościowych prowadzonych w dalszej części pracy.

2.5 Analiza aktualnego stanu badań nad wydajnością silników przetwarzania danych przestrzennych

Wydajność silników przetwarzania danych przestrzennych stanowi istotny obszar badań w dziedzinie systemów bazodanowych, GIS oraz przetwarzania dużych zbiorów danych. Rosnąca skala danych geoprzestrzennych, rozwój systemów lokalizacyjnych oraz coraz częstsze wykorzystanie danych przestrzennych w analizach predykcyjnych powodują, że dobór odpowiedniego silnika obliczeniowego ma bezpośredni wpływ na czas realizacji zapytań, skalowalność procesu analitycznego oraz możliwość praktycznego wykorzystania wyników. W literaturze przedmiotu analizowane są zarówno klasyczne przestrzenne systemy bazodanowe, jak i rozwiązania rozproszone oraz środowiska przeznaczone do przetwarzania dużych danych przestrzennych.

Jednym z istotnych problemów wskazywanych w literaturze jest brak jednego powszechnie przyjętego standardu benchmarkowego dla przestrzennych systemów bazodanowych. Ray, Simion i Brown zaproponowali benchmark Jackpine, którego celem było stworzenie metody oceny wydajności przestrzennych baz danych niezależnej od konkretnego producenta systemu [30]. Autorzy zwrócili uwagę, że ocena wydajności przestrzennych systemów bazodanowych wymaga uwzględnienia zarówno prostych operacji elementarnych, jak i bardziej złożonych scenariuszy odpowiadających rzeczywistym obciążeniom. W zaproponowanej metodyce uwzględniono m.in. zapytania przestrzenne realizowane na

różnych typach danych oraz rozróżnienie pomiędzy mikrobenchmarkami i scenariuszami makroobciążeń. Podejście to pokazuje, że porównanie wydajności silników GIS nie powinno ograniczać się do pojedynczego typu zapytania, lecz powinno obejmować szerszy zestaw operacji reprezentujących różne klasy problemów przestrzennych.

Badania porównawcze dotyczące relacyjnych przestrzennych systemów bazodanowych prowadzone były również w kontekście zestawienia systemów komercyjnych i otwartoźródłowych. Shukla, Shivnani i Shah przeprowadzili eksperymentalne porównanie Oracle Spatial oraz PostgreSQL z rozszerzeniem PostGIS [11]. W badaniu analizowano wybrane zapytania przestrzenne oraz wpływ mechanizmów indeksowania na czas ich wykonania. Autorzy wskazali, że przestrzenne rozszerzenia relacyjnych systemów bazodanowych różnią się sposobem implementacji typów danych, operatorów przestrzennych oraz struktur indeksowych, co może prowadzić do istotnych różnic wydajnościowych. Wyniki tego typu badań mają jednak charakter kontekstowy, ponieważ zależą od doboru danych testowych, konfiguracji środowiska, rodzaju zapytań oraz sposobu wykorzystania indeksów przestrzennych.

Osobny nurt badań dotyczy porównania relacyjnych systemów GIS z bazami NoSQL oferującymi wsparcie dla danych geoprzestrzennych. Bartoszewski, Piórkowski i Lupa przeanalizowali wydajność przetwarzania danych przestrzennych w PostgreSQL/PostGIS oraz MongoDB [31]. W pracy skoncentrowano się na zapytaniach dotyczących danych punktowych oraz na ocenie możliwości wykorzystania wbudowanych mechanizmów geoprzestrzennych MongoDB w porównaniu z relacyjnym modelem PostGIS. Autorzy wskazali, że MongoDB może być użyteczne w prostszych scenariuszach aplikacyjnych związanych z wyszukiwaniem obiektów przestrzennych, jednak zakres obsługiwanych operacji i sposób ich realizacji różnią się od możliwości oferowanych przez wyspecjalizowane rozszerzenia GIS w relacyjnych bazach danych. Wnioski te są istotne z punktu widzenia projektowania systemów analitycznych, ponieważ pokazują, że sama obecność indeksów geoprzestrzennych w systemie NoSQL nie oznacza równoważności funkcjonalnej z pełnym silnikiem GIS.

Wraz ze wzrostem wolumenu danych geoprzestrzennych w literaturze coraz większą uwagę poświęca się również systemom rozproszonym oraz platformom przeznaczonym do przetwarzania dużych danych przestrzennych. Hagedorn, Götze i Sattler przeprowadzili analizę funkcjonalną i wydajnościową frameworków big spatial data działających w ekosystemach Hadoop oraz Spark [32]. Autorzy porównali dostępne rozwiązania pod względem obsługiwanych funkcji oraz wydajności w wybranych scenariuszach, takich jak

filtrowanie przestrzenne i złączenia przestrzenne. Badanie to wskazuje, że w środowiskach rozproszonych istotne znaczenie mają nie tylko same algorytmy przestrzenne, ale również sposób partycjonowania danych, organizacja indeksów oraz koszty komunikacji i koordynacji pomiędzy węzłami obliczeniowymi. W rezultacie systemy tego typu mogą dobrze skalować się dla dużych zbiorów danych, lecz ich efektywność zależy od charakteru zapytań i sposobu przygotowania danych wejściowych.

Podobny kierunek badań reprezentuje praca Alam, Ray i Bhavsar, w której przeprowadzono analizę wydajności systemów przeznaczonych do przetwarzania dużych danych przestrzennych [33]. Autorzy zwrócili uwagę, że porównanie takich systemów powinno obejmować zarówno aspekt funkcjonalny, jak i wydajnościowy, ponieważ poszczególne rozwiązania różnią się zakresem obsługiwanych operacji przestrzennych, sposobem indeksowania, modelem wykonawczym oraz możliwościami skalowania. Badania tego typu pokazują, że w przypadku dużych danych przestrzennych problem wydajności nie sprowadza się wyłącznie do czasu wykonania pojedynczego zapytania, ale obejmuje również koszty przygotowania danych, budowy indeksów, transferu danych oraz ograniczenia wynikające z architektury środowiska obliczeniowego.

Analiza literatury wskazuje, że dotychczasowe badania koncentrują się zwykle na wybranych klasach systemów lub konkretnych typach operacji przestrzennych. Część prac skupia się na klasycznych przestrzennych bazach relacyjnych, inne na porównaniu systemów relacyjnych i NoSQL, a jeszcze inne na środowiskach rozproszonych przeznaczonych do przetwarzania dużych danych przestrzennych. Stosunkowo rzadziej spotykane są natomiast badania obejmujące jednocześnie kilka odmiennych klas silników obliczeniowych, takich jak relacyjne systemy bazodanowe, silniki analityczne typu in-memory, środowiska programistyczne, bazy NoSQL oraz chmurowe hurtownie danych.

Istotnym ograniczeniem części wcześniejszych badań jest również koncentracja na wybranych typach zapytań, bez szerszego rozróżnienia pomiędzy operacjami odległościowymi, topologicznymi, liniowymi i agregacyjnymi. Tymczasem różne klasy operacji przestrzennych mogą w odmienny sposób obciążać silnik obliczeniowy, mechanizmy indeksowania oraz model przechowywania danych. W praktycznych procesach analitycznych, w szczególności w inżynierii cech dla modeli uczenia maszynowego, konieczne jest wykonywanie wielu zróżnicowanych operacji przestrzennych, obejmujących zarówno wyszukiwanie najbliższych obiektów, zapytania promieniowe, przecięcia geometrii, jak i agregacje na dużych zbiorach danych.

Na tle przedstawionego stanu badań niniejsza praca wpisuje się w nurt empirycznych analiz wydajności silników przetwarzania danych przestrzennych, jednocześnie rozszerzając go o porównanie rozwiązań reprezentujących różne klasy architektoniczne. Badanie obejmuje zarówno system relacyjny z rozszerzeniem GIS, silnik analityczny typu in-memory, środowisko programistyczne, dokumentową bazę NoSQL, jak i chmurową hurtownię danych. Dodatkowo eksperymenty zaprojektowano tak, aby uwzględniały różne klasy operacji przestrzennych oraz wpływ wyboru modelu obliczeń przestrzennych i układu odniesienia na czas wykonania zapytań. Takie ujęcie pozwala ocenić nie tylko wydajność pojedynczych silników, lecz także ich praktyczną przydatność w procesach analitycznych i zadaniach inżynierii cech przestrzennych.

3. Charakterystyka analizowanych silników obliczeniowych

W niniejszym rozdziale przedstawiono silniki obliczeniowe wykorzystane w badaniach empirycznych przeprowadzonych w ramach pracy magisterskiej. Celem rozdziału jest scharakteryzowanie analizowanych technologii pod kątem architektury, dostępnych układów odniesienia, modelu przetwarzania danych przestrzennych oraz zakresu operacji istotnych z punktu widzenia dalszych eksperymentów wydajnościowych.

Uwzględniono rozwiązania reprezentujące różne klasy technologiczne, w tym relacyjne systemy bazodanowe, silniki analityczne typu in-memory, środowiska programistyczne, systemy NoSQL oraz chmurowe hurtownie danych. Takie podejście umożliwia porównanie narzędzi o odmiennych założeniach projektowych oraz różnych modelach przetwarzania danych przestrzennych.

Opis każdego silnika koncentruje się na aspektach istotnych z punktu widzenia dalszej części pracy, w szczególności na obsługiwanym modelu obliczeń przestrzennych, sposobie reprezentacji danych geometrycznych oraz typowych scenariuszach zastosowań. Dla każdego z analizowanych rozwiązań wskazano również alternatywne technologie, które nie zostały wykorzystane w badaniach, wraz z uzasadnieniem ich pominięcia.

3.1 Relacyjne systemy bazodanowe – PostgreSQL z rozszerzeniem PostGIS

Relacyjne systemy bazodanowe stanowią jedną z podstawowych klas rozwiązań wykorzystywanych do przechowywania i przetwarzania danych przestrzennych. Ich istotną cechą jest możliwość łączenia klasycznych operacji relacyjnych z operacjami przestrzennymi w ramach jednego modelu danych oraz jednego języka zapytań. W niniejszej pracy klasę tę reprezentuje PostgreSQL z rozszerzeniem PostGIS [10], będący jednym z najczęściej wykorzystywanych otwartoźródłowych rozwiązań GIS w środowisku relacyjnych baz danych.

PostGIS rozszerza funkcjonalność PostgreSQL o obsługę geometrii przestrzennych oraz zestaw operacji zgodnych ze standardami Open Geospatial Consortium. Umożliwia to realizację analiz przestrzennych bez konieczności korzystania z zewnętrznych narzędzi lub silników obliczeniowych.

PostgreSQL z rozszerzeniem PostGIS umożliwia wykonywanie obliczeń zarówno w modelu planarnym, jak i geodezyjnym, w zależności od zastosowanego typu danych przestrzennych. Cecha ta ma istotne znaczenie metodologiczne, ponieważ pozwala na analizę różnic pomiędzy modelami geometry i geography w obrębie jednego, spójnego środowiska

wykonawczego. Dzięki temu możliwe jest ograniczenie wpływu czynników zewnętrznych, takich jak architektura systemu czy sposób zarządzania pamięcią, na interpretację wyników badań empirycznych.

Dojrzałość rozwiązania oraz szeroki zakres wspieranych operacji czynią omawiany silnik istotnym punktem odniesienia w badaniach porównawczych.

Tabela 3.1 Charakterystyka PostgreSQL z rozszerzeniem PostGIS

Cecha	**Charakterystyka**
Typ systemu	relacyjny system bazodanowy
Model przetwarzania	zapytania wykonywane po stronie serwera
Model danych przestrzennych	model geometryczny (geometry) oraz geograficzny (geography)
Obsługiwany model obliczeń	planarny i geodezyjny
Układy odniesienia	obsługa dowolnych układów odniesienia (CRS, EPSG)
Jednostki obliczeń	metryczne (geometry), geodezyjne (geography)
Typy geometrii	Punkt (Point), Linia (LineString), Wielokąt (Polygon)
Indeksowanie przestrzenne	dostępne
Zakres operacji przestrzennych	szeroki, zgodny ze standardami OGC

Źródło: opracowanie własne na podstawie dokumentacji technicznej [10]

W literaturze przedmiotu można znaleźć prace analizujące relacyjne systemy bazodanowe w kontekście przetwarzania danych przestrzennych, w tym badania zestawiające PostgreSQL z rozszerzeniem PostGIS z komercyjnymi rozwiązaniami GIS. Shukla i in. przeprowadzili eksperymentalne porównanie Oracle Spatial i PostGIS na wspólnym zbiorze danych, wskazując na różnice w czasach wykonania wybranych operacji przestrzennych, wynikające z odmiennych implementacji silników oraz mechanizmów indeksowania [11]. Podobnie Greener analizował wydajność wybranych operacji agregujących w Oracle Spatial 12c w porównaniu do ich odpowiedników w PostGIS, podkreślając silną zależność wyników od konkretnego scenariusza obliczeniowego [12]. Arbesser-Rastburg porównywał natomiast Oracle oraz PostgreSQL z PostGIS w kontekście architektury i sposobu realizacji zapytań przestrzennych w relacyjnych systemach bazodanowych [13].

Należy zaznaczyć, że wyniki tego typu badań mają charakter kontekstowy i nie mogą być bezpośrednio uogólniane na wszystkie przypadki użycia. Z tego względu niniejsza praca nie opiera się na zewnętrznych benchmarkach porównujących PostgreSQL z komercyjnymi

systemami bazodanowymi, lecz wykorzystuje PostgreSQL z rozszerzeniem PostGIS jako reprezentatywne, otwartoźródłowe rozwiązanie relacyjne, umożliwiające realizację pełnego zakresu analiz przestrzennych w kontrolowanym środowisku badawczym.

Alternatywne relacyjne systemy bazodanowe oferujące wsparcie dla danych przestrzennych, takie jak Oracle Spatial czy Microsoft SQL Server Spatial, były przedmiotem licznych analiz w literaturze [11,12,13,14]. Nie zostały one jednak uwzględnione jako osobne warianty badawcze w niniejszej pracy, ponieważ ich architektura oraz model obliczeń przestrzennych są zbliżone do podejścia zastosowanego w PostgreSQL z rozszerzeniem PostGIS, a ich uwzględnienie nie wnosiłoby istotnej wartości metodologicznej do prowadzonych porównań.

3.2 Silniki analityczne typu in-memory – DuckDB z rozszerzeniem Spatial

Silniki analityczne typu in-memory stanowią odrębną klasę narzędzi obliczeniowych, projektowanych z myślą o wydajnym wykonywaniu zapytań analitycznych na danych przetwarzanych bezpośrednio w pamięci operacyjnej, bez konieczności uruchamiania serwera bazodanowego. Rozwiązania tego typu są szczególnie popularne w analizach eksploracyjnych, przetwarzaniu wsadowym oraz w zadaniach badawczych, gdzie istotna jest prostota środowiska i minimalny narzut administracyjny.

W niniejszej pracy klasę tę reprezentuje DuckDB wraz z rozszerzeniem Spatial [15,16]. DuckDB jest silnikiem analitycznym działającym w trybie wbudowanego (*embedded*), zaprojektowanym jako „SQLite dla analityki”, oferującym wysoką wydajność zapytań kolumnowych oraz pełną integrację z językami programowania wykorzystywanymi w analizie danych. Rozszerzenie Spatial umożliwia wykonywanie podstawowych operacji przestrzennych bezpośrednio w środowisku DuckDB.

DuckDB z rozszerzeniem Spatial obsługuje wyłącznie planarny model obliczeń przestrzennych, co oznacza brak natywnego wsparcia dla obliczeń geodezyjnych [16]. Z punktu widzenia metodologii badań empirycznych cecha ta upraszcza interpretację wyników, ponieważ wszystkie operacje przestrzenne realizowane są w metrycznych układach odniesienia i w jednolitym modelu matematycznym.

Z tego względu DuckDB z rozszerzeniem Spatial nie jest traktowany jako pełnoprawny system GIS, lecz jako reprezentant lekkich silników analitycznych typu in-memory, co czyni to rozwiązanie interesującym punktem odniesienia dla analiz porównawczych.

Tabela 3.2 Charakterystyka DuckDB z rozszerzeniem Spatial

Cecha	**Charakterystyka**
Typ systemu	silnik analityczny działający w pamięci operacyjnej (in-memory)
Model przetwarzania	wbudowany (embedded)
Model danych przestrzennych	model geometryczny (geometry)
Obsługiwany model obliczeń	planarny
Układy odniesienia	obsługa CRS poprzez transformacje
Jednostki obliczeń	metryczne
Typy geometrii	Punkt (Point), Linia (LineString), Wielokąt (Polygon)
Indeksowanie przestrzenne	ograniczone
Zakres operacji przestrzennych	podstawowy

Źródło: opracowanie własne na podstawie dokumentacji technicznej [15,16]

Z uwagi na brak bezpośrednio porównywalnych, lekkich silników analitycznych typu wbudowanego (*embedded*) oferujących natywne wsparcie dla operacji przestrzennych w modelu SQL, w niniejszym podrozdziale nie zestawiono DuckDB z innymi rozwiązaniami tej klasy. Istnieją co prawda osadzone systemy bazodanowe, takie jak SQLite z rozszerzeniem SpatiaLite, jednak reprezentują one odmienny model przetwarzania danych, ukierunkowany na obciążenia transakcyjne (OLTP), a nie analityczne (OLAP), co ogranicza ich porównywalność architektoniczną z DuckDB.

3.3 Środowiska programistyczne – Python (GeoPandas, Shapely, GEOS)

Środowiska programistyczne odgrywają istotną rolę w przetwarzaniu danych przestrzennych, w szczególności w zadaniach badawczych, eksploracyjnych oraz w procesach przygotowania danych do dalszej analizy. W przeciwieństwie do samodzielnych silników bazodanowych, rozwiązania tego typu opierają się na bibliotekach programistycznych, które realizują operacje przestrzenne bezpośrednio w pamięci aplikacji, najczęściej w ramach jednego procesu.

W niniejszej pracy środowisko to reprezentowane jest przez język Python wraz z bibliotekami GeoPandas oraz Shapely, przy czym operacje geometryczne realizowane są z wykorzystaniem biblioteki GEOS jako niskopoziomowego silnika obliczeniowego [17, 18]. Zestaw ten jest powszechnie stosowany w analizach przestrzennych oraz w badaniach

akademickich, głównie ze względu na prostotę użycia, bogaty ekosystem narzędzi analitycznych oraz łatwą integrację z procesami uczenia maszynowego.

Operacje przestrzenne w omawianym środowisku realizowane są w modelu planarnym, co oznacza brak natywnego wsparcia dla obliczeń geodezyjnych [18]. Wszystkie obliczenia wykonywane są na obiektach geometrycznych przechowywanych w pamięci aplikacji, bez wykorzystania serwerowych mechanizmów optymalizacji charakterystycznych dla systemów bazodanowych. Takie podejście zapewnia dużą elastyczność w analizach eksploracyjnych, jednak przy przetwarzaniu bardzo dużych zbiorów danych może prowadzić do ograniczeń wydajnościowych wynikających z realizacji obliczeń w pamięci aplikacji oraz braku mechanizmów optymalizacji znanych z systemów bazodanowych.

W konsekwencji mechanizmy indeksowania przestrzennego pełnią w tym rozwiązaniu rolę pomocniczą i służą głównie do przyspieszania lokalnych zapytań przestrzennych. Ich skuteczność jest uzależniona od implementacji bibliotek oraz dostępnej pamięci operacyjnej, co ma istotne znaczenie w przypadku przetwarzania dużych zbiorów danych przestrzennych realizowanych w całości w pamięci aplikacji.

Należy zaznaczyć, że środowiska oparte na przetwarzaniu danych w pamięci operacyjnej, takie jak GeoPandas, mogą napotykać dodatkowe ograniczenia stabilności i skalowalności struktur indeksowych przy bardzo dużych zbiorach danych, co zostało również sygnalizowane w dokumentacji i zgłoszeniach społecznościowych tych narzędzi.

Tabela 3.3 Charakterystyka Pythona z GeoPandas, Shapely oraz GEOS

Cecha	**Charakterystyka**
Typ systemu	środowisko programistyczne
Model przetwarzania	w pamięci operacyjnej (in-memory), biblioteki
Model danych przestrzennych	model geometryczny (geometry)
Obsługiwany model obliczeń	planarny
Układy odniesienia	obsługa CRS poprzez transformacje
Jednostki obliczeń	metryczne
Typy geometrii	Punkt (Point), Linia (LineString), Wielokąt (Polygon)
Indeksowanie przestrzenne	dostępne (ograniczone)
Zakres operacji przestrzennych	szeroki (operacje geometryczne)

Źródło: opracowanie własne na podstawie dokumentacji technicznej [17, 18]

W literaturze przedmiotu spotyka się również inne środowiska programistyczne wykorzystywane do przetwarzania danych przestrzennych, w szczególności język R wraz z pakietem *sf*. Środowisko to było przedmiotem licznych analiz w kontekście zastosowań GIS i badań naukowych [19, 20].

Rozwiązania te nie zostały jednak uwzględnione w niniejszej pracy jako osobne silniki obliczeniowe, ponieważ ich model przetwarzania danych przestrzennych jest zbliżony do podejścia zastosowanego w środowisku Python, tj. opiera się na obliczeniach planarnych realizowanych w pamięci aplikacji. Uwzględnienie ich jako dodatkowych wariantów nie wnosiłoby istotnej wartości metodologicznej do porównań prowadzonych w pracy.

3.4 Silniki NoSQL – MongoDB

Systemy bazodanowe typu NoSQL stanowią odmienną klasę rozwiązań w porównaniu do relacyjnych systemów bazodanowych oraz silników analitycznych. Ich architektura koncentruje się na elastycznym modelu danych, wysokiej skalowalności oraz łatwej integracji z aplikacjami rozproszonymi. W kontekście przetwarzania danych przestrzennych systemy te oferują ograniczony, lecz funkcjonalny zestaw mechanizmów, ukierunkowanych na realizację prostych zapytań geoprzestrzennych.

W niniejszej pracy klasę tę reprezentuje MongoDB – dokumentowa baza danych NoSQL [23], umożliwiająca przechowywanie danych przestrzennych w formacie GeoJSON oraz wykonywanie wybranych zapytań geoprzestrzennych z wykorzystaniem indeksów 2dsphere. Zakres obsługiwanych operacji obejmuje przede wszystkim sprawdzanie relacji przestrzennych, takich jak przecięcie, zawieranie oraz zapytania typu near. Zarówno w literaturze przedmiotu, jak i w dokumentacji technicznej podkreśla się, że mechanizmy te zostały zaprojektowane głównie z myślą o zastosowaniach aplikacyjnych, takich jak wyszukiwanie obiektów w pobliżu wskazanej lokalizacji, a nie o realizacji złożonych analiz GIS charakterystycznych dla systemów relacyjnych [22,23].

MongoDB obsługuje wyłącznie własny geograficzny model obliczeń przestrzennych oparty na danych GeoJSON oraz indeksach 2dsphere w układzie odniesienia EPSG:4326. Oznacza to, że wszystkie operacje przestrzenne wykonywane są na powierzchni sfery, z wykorzystaniem przybliżonego modelu geodezyjnego. W praktyce przekłada się to na brak możliwości bezpośredniego wykonywania obliczeń w metrycznych układach odniesienia, co istotnie ogranicza zastosowanie MongoDB w zaawansowanych analizach przestrzennych wymagających wysokiej kontroli dokładności [21, 22].

Dodatkowo wyniki operacji odległościowych wyrażane są w metrach, mimo że współrzędne przechowywane są w stopniach w układzie EPSG:4326.

Z tego względu w niniejszej pracy MongoDB nie jest traktowany jako pełnoprawny silnik GIS, lecz jako reprezentant dokumentowych systemów NoSQL oferujących podstawowe wsparcie dla danych przestrzennych. W badaniach empirycznych jego wykorzystanie ogranicza się do porównań architektonicznych oraz analizy czasów wykonania wybranych, prostych zapytań geoprzestrzennych, co umożliwia ocenę różnic pomiędzy podejściem relacyjnym, analitycznym i dokumentowym w kontekście przetwarzania danych przestrzennych.

Tabela 3.4 Charakterystyka MongoDB

Cecha	**Charakterystyka**
Typ systemu	dokumentowa baza danych NoSQL
Model przetwarzania	dokumentowy (GeoJSON)
Model danych przestrzennych	model geograficzny oparty na GeoJSON (2dsphere)
Obsługiwany model obliczeń	geodezyjny
Układy odniesienia	EPSG:4326
Jednostki obliczeń	metry (model sferyczny)
Typy geometrii	Punkt (Point), Linia (LineString), Wielokąt (Polygon)
Indeksowanie przestrzenne	dostępne (2dsphere)
Zakres operacji przestrzennych	ograniczony

Źródło: opracowanie własne na podstawie dokumentacji technicznej [21, 22]

Alternatywne systemy NoSQL oferujące wsparcie dla danych geoprzestrzennych, w tym inne bazy dokumentowe oraz rozwiązania typu klucz–wartość, były przedmiotem analiz w literaturze [24]. Nie zostały one jednak uwzględnione jako odrębne warianty badawcze, ponieważ ich model obliczeń przestrzennych oraz zakres dostępnych operacji są zbliżone do podejścia zastosowanego w MongoDB i nie wnoszą istotnej wartości metodologicznej w kontekście niniejszej pracy.

3.5 Hurtownie danych w chmurze – BigQuery GIS

Hurtownie danych w chmurze stanowią odrębną klasę systemów obliczeniowych, zaprojektowanych z myślą o przetwarzaniu bardzo dużych wolumenów danych w środowiskach rozproszonych. Ich architektura opiera się na separacji warstwy obliczeniowej i magazynu danych, co umożliwia wysoką skalowalność oraz efektywne wykonywanie zapytań analitycznych bez konieczności zarządzania infrastrukturą sprzętową.

W niniejszej pracy klasę tę reprezentuje BigQuery wraz z rozszerzeniem GIS [25]. BigQuery jest kolumnową hurtownią danych działającą w modelu rozproszonym (*serverless*), oferującą możliwość wykonywania zapytań analitycznych w języku SQL na danych przechowywanych w chmurze. Funkcjonalność GIS umożliwia wykonywanie wybranych operacji przestrzennych bezpośrednio w środowisku BigQuery, co umożliwia analizę danych geoprzestrzennych w skali niedostępnej dla rozwiązań lokalnych [25]. Z tego względu BigQuery GIS pełni w niniejszej pracy rolę reprezentanta chmurowych hurtowni danych oferujących wbudowane wsparcie dla zapytań geoprzestrzennych, a nie zamiennika lokalnych systemów GIS.

BigQuery GIS obsługuje wyłącznie geodezyjny model obliczeń przestrzennych oparty na danych typu geography w układzie odniesienia EPSG:4326. Wszystkie operacje przestrzenne realizowane są na powierzchni elipsoidy, z wykorzystaniem przybliżonych modeli geodezyjnych. Co istotne, wyniki operacji odległościowych wyrażane są w metrach, mimo że współrzędne wejściowe przechowywane są w stopniach. Brak możliwości bezpośredniego wykonywania obliczeń w lokalnych, metrycznych układach odniesienia stanowi istotne ograniczenie w kontekście analiz wymagających precyzyjnej kontroli jednostek i dokładności obliczeń [26].

Mechanizmy optymalizacji zapytań przestrzennych w BigQuery są w pełni zarządzane przez platformę i nie są bezpośrednio konfigurowalne przez użytkownika. Dotyczy to w szczególności indeksowania przestrzennego, które jest realizowane wewnętrznie w ramach silnika zapytań. Takie podejście upraszcza korzystanie z systemu, lecz jednocześnie ogranicza możliwość analizy wpływu poszczególnych mechanizmów optymalizacyjnych na wydajność zapytań [25].

Dodatkowo, z perspektywy metodologii badań empirycznych istotne jest to, że BigQuery funkcjonuje w środowisku chmurowym, gdzie użytkownik nie ma pełnej kontroli nad zasobami sprzętowymi ani nad szczegółową konfiguracją środowiska wykonawczego. BigQuery w standardowej konfiguracji wykorzystuje model rozliczeń on-demand, w którym

zasoby obliczeniowe przydzielane są dynamicznie na potrzeby wykonywanych zapytań, a koszty naliczane są proporcjonalnie do rzeczywistego zużycia mocy obliczeniowej, bez rezerwacji stałych zasobów [27]. W związku z tym wyniki uzyskiwane w tym systemie odzwierciedlają raczej charakterystyki architektury chmurowej niż zachowanie pojedynczego, lokalnego silnika obliczeniowego.

Tabela 3.5 Charakterystyka Google BigQuery GIS

Cecha	**Charakterystyka**
Typ systemu	hurtownia danych w chmurze
Model przetwarzania	rozproszony (serverless)
Model danych przestrzennych	model geograficzny (geography)
Obsługiwany model obliczeń	geodezyjny
Układy odniesienia	EPSG:4326
Jednostki obliczeń	metry (model elipsoidalny)
Typy geometrii	Punkt (Point), Linia (LineString), Wielokąt (Polygon)
Indeksowanie przestrzenne	dostępne (niewidoczne dla użytkownika)
Zakres operacji przestrzennych	umiarkowany

Źródło: opracowanie własne na podstawie dokumentacji technicznej [25,26]

Alternatywne chmurowe platformy analityczne oferujące funkcjonalność geoprzestrzenną były przedmiotem badań i analiz porównawczych w literaturze [25]. Nie zostały one jednak uwzględnione jako osobne warianty badawcze, ponieważ ich model obliczeń przestrzennych oraz charakter środowiska wykonawczego są zbliżone do podejścia zastosowanego w BigQuery GIS i nie wnoszą istotnych różnic metodologicznych w kontekście niniejszej pracy.

3.6 Porównanie architektur analizowanych silników

Analizowane w niniejszej pracy silniki obliczeniowe reprezentują odmienne klasy rozwiązań oraz różne podejścia architektoniczne do przetwarzania danych przestrzennych. Różnice te wynikają przede wszystkim z przyjętego modelu wykonawczego, sposobu przechowywania danych oraz zakresu kontroli nad środowiskiem obliczeniowym. Celem

niniejszego podrozdziału jest syntetyczne uporządkowanie badanych rozwiązań oraz jednoznaczne określenie ich roli w przeprowadzonych badaniach empirycznych.

PostgreSQL z rozszerzeniem PostGIS pełni rolę silnika referencyjnego, stanowiącego punkt odniesienia dla pozostałych rozwiązań, ze względu na szerokie wsparcie dla operacji GIS oraz możliwość wykonywania obliczeń zarówno w modelu planarnym, jak i geodezyjnym.

DuckDB z rozszerzeniem Spatial oraz środowisko Python zostały wykorzystane jako rozwiązania lokalne, działające w modelu planarnym, przydatne odpowiednio do analiz analitycznych oraz etapów preprocessingu danych przestrzennych.

Z kolei MongoDB oraz BigQuery GIS reprezentują podejście oparte na geodezyjnym modelu danych przestrzennych w układzie odniesienia EPSG:4326, charakterystyczne odpowiednio dla dokumentowych systemów NoSQL oraz chmurowych hurtowni danych.

Tabela 3.6 Zestawienie architektur analizowanych silników obliczeniowych

Silnik	**Klasa rozwiązania**	**Model obliczeń przestrzennych**	**Rola w badaniach**
PostgreSQL z rozszerzeniem PostGIS	relacyjny system bazodanowy	planarny / geodezyjny	referencyjna
DuckDB z rozszerzeniem Spatial	silnik analityczny (embedded)	planarny	porównawcza
Python (GeoPandas, Shapely, GEOS)	środowisko programistyczne	planarny	porównawcza
MongoDB	NoSQL (dokumentowy)	geodezyjny	porównawcza
BigQuery GIS	hurtownia danych w chmurze	geodezyjny	porównawcza

Źródło: opracowanie własne

Zestawienie przedstawione w tabeli 3.6 porządkuje analizowane silniki obliczeniowe pod względem ich architektury, modelu obliczeń przestrzennych oraz pełnionej roli w badaniach empirycznych. Tak dobrany zestaw silników umożliwia porównanie rozwiązań lokalnych i serwerowych z systemami rozproszonymi oraz ocenę wpływu architektury systemu i modelu obliczeń przestrzennych na sposób realizacji zapytań geoprzestrzennych w dalszej części pracy.

4. Metodyka badań empirycznych

Rozdział ten przedstawia metodykę badań empirycznych przeprowadzonych w celu porównania wybranych silników obliczeniowych wykorzystywanych do przetwarzania danych przestrzennych. Opisano w nim założenia badawcze, wykorzystane zbiory danych, konfigurację środowiska testowego, zastosowane układy odniesienia przestrzennego oraz scenariusze eksperymentów. Celem rozdziału jest zapewnienie pełnej przejrzystości procesu badawczego oraz umożliwienie poprawnej interpretacji wyników zaprezentowanych w dalszej części pracy.

Metodyka została zaprojektowana w sposób umożliwiający porównanie rozwiązań o odmiennych architekturach, przy jednoczesnym zachowaniu spójności matematycznej i kontrolowanego charakteru eksperymentów. Szczególną uwagę poświęcono doborowi modeli obliczeń przestrzennych, sposobowi indeksowania danych oraz zasadom raportowania wyników czasowych, tak aby ograniczyć wpływ czynników losowych i środowiskowych na uzyskane rezultaty.

4.1 Cel i zakres badań empirycznych

Celem badań empirycznych przeprowadzonych w niniejszej pracy jest porównanie wydajności oraz charakterystyki działania wybranych silników obliczeniowych wykorzystywanych do przetwarzania danych przestrzennych, ze szczególnym uwzględnieniem operacji realizowanych w metrycznych, dwuwymiarowych układach odniesienia. Badania mają charakter porównawczy i zostały zaprojektowane z myślą o zachowaniu możliwie zbliżonych scenariuszy testowych w różnych środowiskach obliczeniowych, przy jednoczesnym uwzględnieniu różnic architektonicznych pomiędzy analizowanymi silnikami, w szczególności w zakresie modelu wykonawczego, sposobu przechowywania danych oraz dostępnych mechanizmów optymalizacji zapytań.

Zakres badań empirycznych nie obejmuje analizy jakości danych wejściowych ani oceny skuteczności modeli uczenia maszynowego. Praca koncentruje się na pomiarze czasu wykonania operacji przestrzennych oraz analizie wpływu zastosowanych układów odniesienia, modeli obliczeń oraz mechanizmów indeksowania na wydajność przetwarzania danych. Celem badań nie jest wskazanie jednego „najlepszego” rozwiązania, lecz ocena wpływu przyjętej architektury i modelu obliczeń przestrzennych na przebieg oraz koszt realizacji operacji.

4.2 Zbiory danych wykorzystane w badaniach

W badaniach empirycznych wykorzystano zestawy danych przestrzennych zapisane w postaci plików CSV, w których geometrie obiektów przechowywane są w formacie WKT (Well-Known Text [2]). Taki sposób zapisu danych umożliwia jednolite przygotowanie danych wejściowych oraz ich dalsze przetwarzanie w różnych środowiskach obliczeniowych, niezależnie od docelowego silnika bazodanowego lub analitycznego, przy jednoczesnym jawnie kontrolowanym przypisaniu układu odniesienia przestrzennego na etapie importu danych.

Zbiory danych obejmują obiekty przestrzenne o zróżnicowanej charakterystyce geometrycznej, w tym obiekty punktowe, liniowe oraz powierzchniowe, a także znacząco różniące się skalą — od kilku tysięcy do kilkudziesięciu milionów obiektów. Umożliwia to analizę obciążenia obliczeniowego silników w scenariuszach charakteryzujących się zróżnicowaną złożonością geometryczną. Dane pochodzą zarówno z otwartych źródeł referencyjnych, jak i z procesów generowania danych.

Tabela 4.2 Charakterystyka zbiorów danych wykorzystanych w badaniach empirycznych

Zbiór danych	**Typ geometrii**	**Liczba obiektów**	**Źródło**	**Zastosowanie w badaniach**
dat_poi	Punkt (Point)	903,735	OpenStreetMap	zapytania odległościowe, analizy sąsiedztwa
geo_polska	Wielokąt/Obszar (Polygon - Area)	2,876	PRG Geoportal	relacje przestrzenne, granice administracyjne
osm_roads	Linia (Line - LineString)	1,076,076	OpenStreetMap	analizy liniowe, relacje przestrzenne
geo_hex	Wielokąt/Obszar (Polygon - Area)	30,943,061	dane syntetyczne (generowane)	testy wydajnościowe, agregacje przestrzenne

Źródło: opracowanie własne na podstawie danych z: OpenStreetMap [28], PRG Geoportal [29]

Dane te stanowią wejście do dalszych etapów badań i zostały wykorzystane zarówno w procesach preprocessingu, jak i w scenariuszach eksperymentów.

4.3 Środowisko badawcze i konfiguracja eksperymentów

Badania empiryczne przeprowadzono w środowisku lokalnym, obejmującym silniki PostgreSQL z rozszerzeniem PostGIS, DuckDB z rozszerzeniem Spatial, środowisko Python z bibliotekami GeoPandas, Shapely i GEOS oraz dokumentową bazę danych MongoDB, a także w środowisku chmurowym w przypadku BigQuery GIS. Taki dobór środowisk wynika z charakteru analizowanych silników, których architektura w naturalny sposób determinuje sposób uruchamiania eksperymentów. W konsekwencji część wyników odzwierciedla zachowanie silników lokalnych i serwerowych uruchamianych na kontrolowanym sprzęcie, a część zachowanie środowiska typu rozproszonego (*serverless*), w którym zasoby obliczeniowe są zarządzane przez dostawcę usługi.

W przypadku eksperymentów wykonywanych lokalnie zastosowano jednolitą konfigurację sprzętową i systemową, tak aby ograniczyć wpływ czynników zewnętrznych na czas wykonania operacji. Wszystkie testy lokalne realizowano bez wykorzystania maszyn wirtualnych lub kontenerów, a bezpośrednio na systemie operacyjnym, co pozwala na możliwie bezpośredni pomiar kosztu obliczeniowego analizowanych operacji. Parametry środowiska sprzętowego przedstawiono w tabeli 4.3a.

Tabela 4.3a Konfiguracja sprzętowa środowiska lokalnego

Sprzęt	**Specyfikacja**
Procesor	AMD Ryzen 9 7900 (12 rdzeni / 24 wątki), 3.7–5.4 GHz
Pamięć RAM	32 GB (31,1 GB dostępne), DDR5 6000 MHz CL30
Dysk SSD	Lexar NQ790 1 TB, M.2 PCIe Gen4 NVMe
System operacyjny	Windows 11 Pro (wersja 25H2)

Źródło: opracowanie własne

Wyniki uzyskane w środowisku BigQuery GIS należy interpretować z uwzględnieniem specyfiki architektury chmurowej. Użytkownik nie ma w tym przypadku pełnej kontroli nad zasobami sprzętowymi ani nad szczegółową konfiguracją silnika wykonawczego, a czas wykonania zapytań odzwierciedla łączny czas realizacji operacji w środowisku zarządzanym przez platformę. Z tego względu badania w BigQuery GIS mają charakter porównania architektonicznego, a nie pomiaru w pełni kontrolowanego w sensie sprzętowym. Podejście to jest jednak zgodne z celem pracy, ponieważ jednym z analizowanych czynników jest wpływ

modelu wykonawczego — lokalnego, serwerowego oraz chmurowego — na koszt realizacji operacji przestrzennych.

W celu zapewnienia powtarzalności i jednoznacznej interpretacji wyników, w tabeli 4.3b zestawiono wersje oprogramowania wykorzystanego w badaniach empirycznych.

Tabela 4.3b Wersje oprogramowania wykorzystanego w badaniach

Środowisko	Wersja oprogramowania
PostgreSQL z rozszerzeniem PostGIS	PostgreSQL 18.1, PostGIS 3.6
DuckDB z rozszerzeniem Spatial	Python 3.14.0, DuckDB 1.4.2
Python (GeoPandas, Shapely, GEOS)	Python 3.14.0, GeoPandas 1.1.1, Shapely 2.1.2, GEOS 3.13.1, pyproj 3.7.2; Rtree 1.4.1, Pandas 2.3.3, NumPy 2.3.5
MongoDB	MongoDB 8.2.2
BigQuery GIS	środowisko chmurowe (stan na 12.2025), konfiguracja infrastruktury zarządzana przez dostawcę

Źródło: opracowanie własne

4.4 Układy odniesienia przestrzennego i modele obliczeń

Wszystkie dane przestrzenne wykorzystane w badaniach empirycznych obejmowały obszar terytorium Polski, dlatego wybór podstawowego układu odniesienia padł na krajowy układ EPSG:2180. Układ ten umożliwia wykonywanie obliczeń planarnych w jednostkach metrycznych oraz zapewnia jednoznaczną interpretację wyników operacji przestrzennych.

Układ odniesienia EPSG:4326 wykorzystano wyłącznie w scenariuszach, w których było to wymagane przez ograniczenia technologiczne analizowanych silników lub gdy celem eksperymentu było porównanie zachowania operacji przestrzennych w modelu planarnym i geodezyjnym. W przypadku PostgreSQL z rozszerzeniem PostGIS obliczenia geodezyjne realizowano z użyciem typu geography, natomiast w wybranych scenariuszach zastosowano również typ geometry w układzie EPSG:4326. Wynikało to z faktu, że część analizowanych operacji nie jest dostępna lub w pełni wspierana w modelu geodezyjnym. Dla pozostałych silników zastosowanie układu EPSG:4326 było konsekwencją ich architektury, ponieważ obsługują one wyłącznie geodezyjny model obliczeń przestrzennych oparty na tym układzie odniesienia.

4.5 Indeksowanie danych przestrzennych

Indeksowanie danych przestrzennych stanowi jeden z kluczowych czynników wpływających na wydajność zapytań geoprzestrzennych, w szczególności w przypadku dużych zbiorów danych oraz operacji opartych na relacjach przestrzennych. W niniejszych badaniach przyjęto zasadę stosowania indeksów wszędzie tam, gdzie było to technicznie możliwe i zgodne z możliwościami danego silnika obliczeniowego. Celem takiego podejścia było ograniczenie wpływu potencjalnych nieoptymalności konfiguracyjnych na wyniki pomiarów oraz zapewnienie porównywalnych warunków testowych.

W relacyjnym systemie bazodanowym PostgreSQL z rozszerzeniem PostGIS wykorzystano klasyczne indeksy atrybutowe dla kolumn nieprzestrzennych oraz indeksy przestrzenne oparte na strukturach GiST i SP-GiST dla kolumn geometrycznych.

W silniku DuckDB z rozszerzeniem Spatial zastosowano indeksy przestrzenne oparte na strukturach R-tree. Zakres i sposób wykorzystania indeksów w DuckDB jest jednak bardziej ograniczony niż w dojrzałych systemach bazodanowych, co wynika z analitycznego i wbudowanego (*embedded*) charakteru tego silnika.

W przypadku MongoDB zastosowano indeksy typu 2dsphere, umożliwiające realizację zapytań geoprzestrzennych w geodezyjnym modelu danych opartym na układzie EPSG:4326. Indeksy te są ściśle powiązane z typem danych geography i stanowią wymagany mechanizm do wykonywania zapytań przestrzennych w tym środowisku.

W środowisku BigQuery GIS mechanizmy indeksowania, zarówno klasycznego, jak i przestrzennego, są w pełni zarządzane przez platformę chmurową i nie są bezpośrednio konfigurowalne przez użytkownika. Użytkownik nie ma dostępu do szczegółów implementacyjnych struktur indeksowych ani do ich parametrów.

W przypadku środowiska Python z biblioteką GeoPandas brak jest klasycznego mechanizmu indeksowania zapytań znanego z systemów bazodanowych. Operacje geoprzestrzenne wykonywane są na obiektach przechowywanych w pamięci aplikacji, a optymalizacja zapytań realizowana jest poprzez pomocnicze struktury danych, takie jak drzewa STRtree lub indeksy przestrzenne dostępne za pośrednictwem atrybutu sindex. Struktury te umożliwiają przyspieszenie wybranych operacji przestrzennych, jednak nie są równoważne z indeksami przestrzennymi zarządzanymi przez silnik bazodanowy i nie oferują zaawansowanych mechanizmów planowania zapytań.

Dodatkowo, w środowisku Python/GeoPandas zastosowano optymalizacje pamięciowe polegające na przechowywaniu wybranych kolumn atrybutowych o niskiej kardynalności jako

typu category w bibliotece Pandas. Należy podkreślić, że rozwiązanie to nie stanowi indeksu atrybutowego w sensie bazodanowym i nie wpływa bezpośrednio na planowanie zapytań przestrzennych, a jedynie ogranicza zużycie pamięci operacyjnej.

Kolumny niegeometryczne wykorzystywane w zapytaniach nie były przedmiotem porównań funkcjonalnych. W celu zapewnienia porównywalnych warunków wydajnościowych we wszystkich badanych silnikach zastosowano indeksy atrybutowe na wybranych kolumnach (dat_poi.category, geo_polska.typ, osm_roads.highway), tak aby filtrowanie atrybutowe nie wpływało na pomiar wydajności operacji przestrzennych. Wpływ zastosowanych mechanizmów indeksowania został uwzględniony w interpretacji wyników empirycznych przedstawionych w dalszej części pracy.

4.6 Scenariusze eksperymentów

W niniejszym podrozdziale przedstawiono zestaw scenariuszy eksperymentalnych wykorzystanych do oceny wydajności oraz możliwości funkcjonalnych analizowanych silników obliczeniowych. Scenariusze zaprojektowano w taki sposób, aby obejmowały różne klasy operacji przestrzennych, w tym zapytania odległościowe, operacje geometryczne i topologiczne, analizy danych o charakterze liniowym oraz agregacje realizowane na dużych zbiorach danych. Każdy scenariusz był realizowany z wykorzystaniem tych samych zbiorów danych oraz przy zachowaniu spójnych założeń metodologicznych.

4.6.1 Założenia ogólne eksperymentów

Zestaw eksperymentów empirycznych zaprojektowano w sposób umożliwiający ocenę zachowania analizowanych silników obliczeniowych w typowych scenariuszach przetwarzania danych przestrzennych. Eksperymenty podzielono na logiczne grupy odpowiadające różnym klasom operacji przestrzennych oraz zróżnicowanej skali przetwarzanych zbiorów danych. Podział ten obejmuje eksperymenty odległościowe (E1–E4), geometryczne i topologiczne (E5–E8), eksperymenty dotyczące obiektów liniowych (E9–E12) oraz eksperymenty agregacyjne na siatkach heksagonalnych (E13–E16).

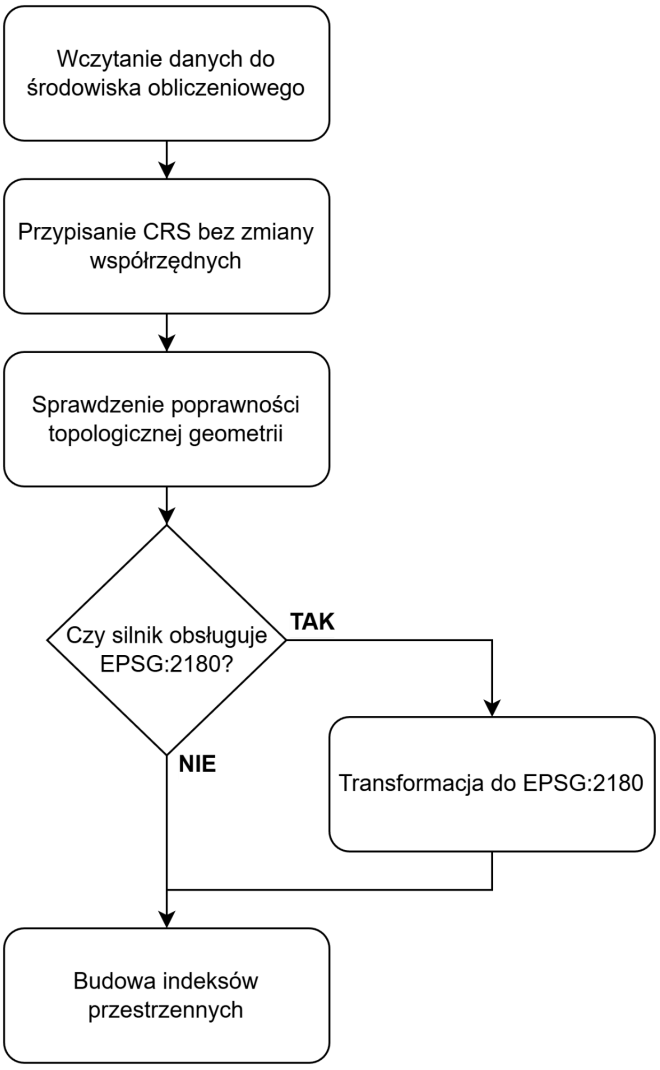
Ze względu na istotne różnice architektoniczne oraz odmienne modele danych przestrzennych stosowane w analizowanych silnikach, nie wszystkie scenariusze eksperymentalne są możliwe do realizacji w każdym środowisku. Brak możliwości wykonania danego eksperymentu nie jest traktowany jako wada metodyki badawczej, lecz

jako ograniczenie danego systemu. Informacja ta została jawnie uwzględniona w analizie porównawczej przedstawionej w dalszej części pracy.

4.6.2 Założenia preprocessingu danych wejściowych

Przed realizacją właściwych eksperymentów empirycznych dane przestrzenne poddano ujednoliconemu procesowi przygotowania (preprocessing), którego celem było zapewnienie spójności danych wejściowych oraz porównywalnych warunków testowych w różnych środowiskach obliczeniowych. Proces ten obejmował weryfikację typów i poprawności geometrii, transformacje układów odniesienia przestrzennego oraz budowę struktur indeksowych, realizowane zgodnie z założeniami opisanymi w podrozdziałach 4.4 i 4.5. Techniczna realizacja poszczególnych etapów mogła różnić się w zależności od specyfiki środowiska, co zostało uwzględnione w analizie wyników.

Źródło: opracowanie własne



Rys. 4.6.2 Schemat preprocessingu danych wejściowych

4.6.3 Eksperymenty odległościowe i najbliższego sąsiada (E1–E4)

Eksperymenty odległościowe obejmują scenariusze E1–E4 i koncentrują się na analizie obliczeń dystansowych oraz zapytań sąsiedztwa realizowanych w różnych modelach obliczeń przestrzennych. Scenariusze te odzwierciedlają jedne z najczęściej wykorzystywanych operacji w praktycznych zastosowaniach systemów GIS, w szczególności w zadaniach związanych z wyszukiwaniem najbliższych obiektów, realizacją zapytań zasięgowych oraz wyznaczaniem odległości względem obiektów referencyjnych. Z tego względu stanowią one reprezentatywną grupę operacji umożliwiającą porównanie sposobu realizacji zapytań przestrzennych w analizowanych silnikach obliczeniowych.

Szczegółowe zestawienie eksperymentów odległościowych wraz z ich celem przedstawiono w tabeli 4.6.3.

Tabela 4.6.3 Eksperymenty odległościowe i najbliższego sąsiada (E1–E4)

Eksperyment	Cel eksperymentu	Typ operacji przestrzennych
E1	Wyznaczenie najbliższego punktu POI względem zadanego punktu referencyjnego	najbliższy sąsiad (nearest neighbor), dystans
E2	Wyznaczenie najbliższego punktu POI w każdej kategorii obiektów względem zadanego punktu referencyjnego	najbliższy sąsiad (nearest neighbor) z filtrowaniem, dystans
E3	Zliczenie liczby punktów POI w zadanych promieniach od punktu referencyjnego	zapytania zasięgowe (range queries)
E4	Obliczenie odległości punktów POI do granic jednostek administracyjnych	dystans, relacje topologiczne

Źródło: opracowanie własne

4.6.4 Eksperymenty geometryczne i topologiczne (E5–E8)

Eksperymenty geometryczne i topologiczne obejmują scenariusze E5–E8 i koncentrują się na operacjach wymagających analizy relacji przestrzennych oraz przekształceń geometrycznych obiektów powierzchniowych. W przeciwieństwie do eksperymentów odległościowych, scenariusze te w większym stopniu obciążają mechanizmy topologiczne silników GIS oraz ujawniają ograniczenia wynikające z braku wsparcia dla określonych operacji geometrycznych.

Eksperymenty tej grupy obejmują zarówno podstawowe obliczenia cech geometrycznych, jak i bardziej złożone operacje, takie jak przecięcia, agregacje topologiczne czy generowanie diagramów Voronoi. Ze względu na charakter tych operacji, część scenariuszy może być realizowana wyłącznie w modelu planarnym (typ geometry), natomiast w innych przypadkach stosowany jest wariant mieszany, łączący operacje topologiczne wykonywane planarnie z obliczeniami metrycznymi realizowanymi w modelu geodezyjnym.

Szczegółowe zestawienie eksperymentów geometrycznych i topologicznych wraz z ich celem przedstawiono w tabeli 4.6.4.

Tabela 4.6.4 Eksperymenty geometryczne i topologiczne (E5–E8)

Eksperyment	Cel eksperymentu	Typ operacji przestrzennych
E5	Obliczenie podstawowych cech geometrycznych jednostek administracyjnych (powierzchnia, obwód, centroid)	pole powierzchni (area), obwód (perimeter), centroid
E6	Przecięcie buforów gmin z granicami województw oraz ocena kosztu operacji przecięć	bufory (buffer) oraz przecięcia (intersection)
E7	Zliczenie liczby punktów POI w jednostkach administracyjnych na różnych poziomach hierarchii	relacje zawierania (contains)
E8	Generowanie diagramu Voronoi dla zbioru punktów POI oraz przecięcia komórek z granicami województw	diagram Voronoi (Voronoi), przecięcia (intersection)

Źródło: opracowanie własne

4.6.5 Eksperymenty na obiektach liniowych (E9–E12)

Eksperymenty na obiektach liniowych obejmują scenariusze E9–E12 i koncentrują się na analizie operacji wykonywanych na danych o charakterze liniowym, w szczególności na sieci drogowej. Scenariusze te umożliwiają analizę obliczeń długości, zapytań sąsiedztwa punkt–linia oraz agregacji opartych na atrybutach obiektów liniowych.

W tej grupie eksperymentów istotne znaczenie ma sposób realizacji obliczeń długości odcinków dróg, który różni się w zależności od zastosowanego modelu obliczeń przestrzennych. W wariancie planarnym (typ geometry w układzie EPSG:2180) długości wyznaczane są bezpośrednio na płaszczyźnie, natomiast w wariancie geodezyjnym (typ geography w układzie EPSG:4326) obliczenia realizowane są na powierzchni elipsoidy.

Różnice te mają wpływ zarówno na interpretację wyników, jak i na koszt obliczeniowy poszczególnych operacji.

Eksperymenty liniowe umożliwiają również ocenę skuteczności indeksów przestrzennych w zapytaniach typu nearest neighbor oraz w zapytaniach zasięgowych, w których obiekty liniowe są filtrowane względem punktów referencyjnych.

Szczegółowe zestawienie eksperymentów na obiektach liniowych wraz z ich celem przedstawiono w tabeli 4.6.5.

Tabela 4.6.5 Eksperymenty na obiektach liniowych (E9–E12)

Eksperyment	Cel eksperymentu	Typ operacji przestrzennych
E9	Obliczenie średniej długości odcinków dróg w podziale na kategorię highway	długość (length), agregacja
E10	Wyznaczenie najbliższego odcinka drogi dla punktów POI	najbliższy sąsiad (nearest neighbor), punkt–linia
E11	Identyfikacja najdłuższego odcinka drogi w każdej kategorii	długość (length)
E12	Obliczenie łącznej długości dróg w zadanym promieniu od punktów POI	zapytania zasięgowe (range queries), długość (length)

Źródło: opracowanie własne

4.6.6 Eksperymenty agregacyjne na siatkach heksagonalnych (E13–E16)

Eksperymenty agregacyjne na siatkach heksagonalnych obejmują scenariusze E13–E16 i zostały zaprojektowane w celu oceny zachowania analizowanych silników w warunkach przetwarzania bardzo dużych zbiorów danych przestrzennych. Scenariusze te koncentrują się na operacjach agregacyjnych oraz złożonych relacjach przestrzennych realizowanych na siatce heksagonalnej o wysokiej rozdzielczości.

Zastosowanie regularnej siatki heksagonalnej umożliwia testowanie skalowalności operacji przestrzennych w sposób niezależny od administracyjnego podziału terytorialnego. Jednocześnie bardzo duża liczba obiektów heksagonalnych stanowi istotne obciążenie dla mechanizmów indeksowania, operacji topologicznych oraz agregacji, co pozwala na ujawnienie ograniczeń architektonicznych poszczególnych silników.

Ze względu na wysoką złożoność obliczeniową część scenariuszy może być niewykonalna w niektórych środowiskach, co zostało jawnie uwzględnione w dalszej analizie

porównawczej. Szczegółowe zestawienie eksperymentów agregacyjnych na siatkach heksagonalnych wraz z ich celem przedstawiono w tabeli 4.6.6.

Tabela 4.6.6 Eksperymenty agregacyjne na siatkach heksagonalnych (E13–E16)

Eksperyment	Cel eksperymentu	Typ operacji przestrzennych
E13	Agregacja geometrii heksagonów w obrębie województw na próbie 1 000 000 obiektów	połączenie przestrzenne (spatial join), łączenie geometrii (union), agregacja
E14	Zliczenie liczby punktów POI przypadających na komórki siatki heksagonalnej	połączenie przestrzenne (spatial join), punkt–wielokąt
E15	Obliczenie łącznej długości dróg w obrębie komórek siatki heksagonalnej	przecięcie (intersection), długość (length)
E16	Przypisanie komórek siatki heksagonalnej do województw z wyznaczeniem pola komórki oraz pola części wspólnej z województwem	połączenie przestrzenne (spatial join), przecięcie (intersection), pole powierzchni (area)

Źródło: opracowanie własne

4.7 Podsumowanie metodyki badań empirycznych

Przyjęta metodyka badań empirycznych umożliwia porównanie analizowanych silników obliczeniowych w zróżnicowanych scenariuszach operacji przestrzennych, przy zachowaniu spójnych i kontrolowanych warunków testowych. Ograniczenia funkcjonalne poszczególnych środowisk zostały uwzględnione jako element ich charakterystyki architektonicznej, a nie jako wada procesu badawczego. Przygotowana metodyka stanowi bezpośrednią podstawę do analizy wyników empirycznych zaprezentowanych w kolejnym rozdziale.

5. Wyniki badań empirycznych

W niniejszym rozdziale przedstawiono wyniki badań empirycznych przeprowadzonych zgodnie z metodyką opisaną w Rozdziale 4. Zaprezentowane wyniki obejmują zarówno pomiary czasów preprocessingu danych przestrzennych, jak i czasy wykonania operacji przestrzennych realizowanych w ramach poszczególnych scenariuszy eksperymentalnych, wraz z towarzyszącymi im obserwacjami empirycznymi dotyczącymi zachowania analizowanych silników obliczeniowych. Interpretacja uzyskanych wyników oraz wnioski o charakterze syntetycznym zostały przedstawione w kolejnym rozdziale pracy.

5.1 Organizacja i zasady prezentacji wyników

Wyniki pomiarów czasowych prezentowane są w formie tabel oraz wykresów. Tabele zawierają wartości pomiarowe uzyskane w ramach poszczególnych eksperymentów, natomiast wykresy służą do porównania wyników osiągniętych przez analizowane silniki w obrębie tej samej klasy operacji przestrzennych. Raportowane czasy wykonania stanowią wartości uśrednione z kilku wykonań danego scenariusza eksperymentalnego, co pozwala ograniczyć wpływ fluktuacji środowiskowych i zapewnić porównywalność wyników.

W przypadku eksperymentów wykonywanych po raz pierwszy po uruchomieniu środowiska obliczeniowego, w tym po załadowaniu danych lub utworzeniu struktur indeksowych, raportowane wartości oznaczano jako cold run, co zostało jawnie wskazane w nawiasach. Dla czasów wykonania przekraczających 10 sekund nie rozróżniano pomiarów typu cold run i warm run (wykonanie zapytania przy wykorzystaniu cache), ponieważ obserwowane różnice miały charakter marginalny i nie wpływały istotnie na dalszą analizę porównawczą.

W środowisku GeoPandas raportowano pojedyncze wartości czasowe bez rozróżnienia na przebiegi typu cold i warm, ponieważ obliczenia realizowane są bez mechanizmów cache’owania charakterystycznych dla silników bazodanowych.

W przypadku silnika BigQuery GIS raportowane wartości obejmują dwie metryki. Wartość podana bez nawiasu oznacza czas rzeczywisty wykonania zapytania (elapsed time), natomiast wartość podana w nawiasie oznacza łączny nakład pracy obliczeniowej (slot time consumed), który może znacząco przekraczać czas rzeczywisty ze względu na równoległe wykorzystanie zasobów w środowisku typu serverless.

5.2 Preprocessing danych

Preprocessing danych stanowił etap przygotowawczy poprzedzający realizację właściwych eksperymentów empirycznych i został przeprowadzony zgodnie z metodyką opisaną w Rozdziale 4. Jego celem było zapewnienie spójnych i porównywalnych warunków testowych dla wszystkich analizowanych silników obliczeniowych, niezależnie od ich architektury oraz modelu przetwarzania danych przestrzennych.

Zakres wykonanych operacji obejmował m.in. import danych, weryfikację i przygotowanie geometrii, transformację układów odniesienia oraz budowę struktur indeksowych, przy czym ich techniczna realizacja mogła różnić się pomiędzy środowiskami. Ograniczenia funkcjonalne poszczególnych silników zostały uwzględnione przy interpretacji wyników empirycznych przedstawionych w dalszej części rozdziału.

5.2.1 Wyniki pomiarów czasowych preprocessingu

Pierwszym etapem preprocessingu był import danych z plików CSV zawierających geometrie zapisane w formacie WKT (Well-Known Text). Czasy importu danych w poszczególnych silnikach zestawiono w tabeli 5.2.1a.

Tabela 5.2.1a Czasy importu danych z plików CSV z geometrią w formacie WKT

Silnik	dat_poi	geo_polska	osm_roads	geo_hex	Łącznie
PostgreSQL	2.66s	9.13s	4.31s	3m 24s	3m 40s
DuckDB	1.10s	8.44s	1.49s	15.30s	26.33s
GeoPandas	1.43s	1.81s	2.29s	1m 21s	1m 26s
MongoDB	6.76s	1.72s	8.60s	4m 16s	4m 33s
BigQuery	8.45s (11.45s)	33.18s (31.65s)	21.50s (33.57s)	24.44s (23m 36s)	1m 27s (24m 52s)

Źródło: opracowanie własne

W środowisku DuckDB etap importu obejmował dodatkowo operację odwrócenia kolejności współrzędnych (flip coordinates), co zostało uwzględnione w raportowanych czasach.

Analiza łącznych czasów importu danych wskazuje na wyraźne różnice pomiędzy badanymi silnikami obliczeniowymi już na etapie preprocessingu. Najkrótszy łączny czas importu uzyskano w środowisku DuckDB (26,33 s), natomiast najwyższy w przypadku

MongoDB (4 min 33 s). W środowisku BigQuery GIS rzeczywisty czas wykonania operacji importu (*elapsed time*) wyniósł 1 min 27 s, co plasuje to rozwiązanie w grupie wyników pośrednich. Zbliżony rezultat osiągnęło środowisko Python/GeoPandas (1 min 26 s), natomiast PostgreSQL z rozszerzeniem PostGIS charakteryzował się wyraźnie wyższym kosztem importu danych (3 min 40 s). Zestawienie to pokazuje, że już na etapie importu danych wybór silnika obliczeniowego istotnie wpływa na całkowity koszt przygotowania danych do dalszych analiz.

Kolejnym etapem preprocessingu było przypisanie układu odniesienia przestrzennego do zaimportowanych geometrii. Operacja ta polegała na jawnym ustawieniu identyfikatora układu odniesienia (SRID) na wartość EPSG:4326 przy użyciu mechanizmów takich jak ST_SetSRID i była realizowana wyłącznie w silnikach oferujących silne typowanie danych przestrzennych. W środowisku DuckDB etap ten został pominięty ze względu na brak jawnego typowania geometrii oraz brak mechanizmu przechowywania informacji o SRID. Zestawienie czasów przypisania układu odniesienia przedstawiono w tabeli 5.2.1b.

Tabela 5.2.1b Czasy przypisania układu odniesienia przestrzennego (SRID = EPSG:4326)

Silnik	**dat_poi**	**geo_polska**	**osm_roads**	**geo_hex**	**Łącznie**
PostgreSQL	6.51s	7.70s	14.09s	17m 17s	17m 45s
DuckDB	n/d				n/d
GeoPandas	1.44s	2.69s	3.66s	4m 33s	4m 40s
MongoDB	10.18s	4.46s	16.81s	7m 42s	8m 13s
BigQuery	9.07s (15.03s)	40.02s (1m 2s)	53.51s (5m 44s)	42.98s (2h 24m)	2m 25s (2h 31m)

Źródło: opracowanie własne

Analiza łącznych czasów przypisania układu odniesienia przestrzennego wskazuje na istotne różnice pomiędzy analizowanymi silnikami obliczeniowymi. Najkrótszy łączny czas tego etapu uzyskano w środowisku Python/GeoPandas (4 min 40 s), natomiast najwyższy w przypadku PostgreSQL z rozszerzeniem PostGIS (17 min 45 s), co wynika z kosztu operacji wykonywanych na bardzo dużym zbiorze geo_hex. W środowisku MongoDB łączny czas przypisania SRID wyniósł 8 min 13 s i był wyraźnie niższy niż w PostgreSQL, lecz istotnie wyższy niż w GeoPandas. W przypadku BigQuery GIS rzeczywisty czas wykonania tego

etapu (*elapsed time*) wyniósł 2 min 25 s, co plasuje to środowisko jako najszybsze spośród silników realizujących ten etap preprocessingu.

Następnym etapem preprocessingu była weryfikacja poprawności geometrii oraz jej ewentualna korekta. W środowisku Python/GeoPandas zastosowano umowną metodę walidacji geometrii z wykorzystaniem operacji buforowania zerowego (buffer(0)), natomiast w MongoDB oraz BigQuery GIS etap ten nie był wykonywany ze względu na brak dostępnych mechanizmów walidacji i korekty geometrii na poziomie zapytań. Dla zbioru geo_hex w środowisku GeoPandas operacja ta była dodatkowo realizowana partiami w celu zapewnienia stabilności wykonania. Zestawienie czasów weryfikacji i korekty geometrii przedstawiono w tabeli 5.2.1c.

Tabela 5.2.1c Czasy weryfikacji i korekty geometrii

Silnik	dat_poi	geo_polska	osm_roads	geo_hex	Łącznie
PostgreSQL	0.36s	0.46s	6.04s	5m 30s	5m 36s
DuckDB	0.06s	0.60s	0.07s	5.35s	6.08s
GeoPandas	0.03s	0.55s	0.12s	1m 8s	1m 8s
MongoDB	n/d				n/d
BigQuery	n/d				n/d

Źródło: opracowanie własne

Analiza łącznych czasów weryfikacji i korekty geometrii wskazuje na istotne różnice pomiędzy analizowanymi silnikami obliczeniowymi. Najkrótszy łączny czas tego etapu uzyskano w środowisku DuckDB (6,08 s), natomiast najwyższy w przypadku PostgreSQL z rozszerzeniem PostGIS (5 min 36 s), co było związane z kosztami przetwarzania bardzo dużego zbioru geo_hex. W środowisku Python/GeoPandas łączny czas weryfikacji i korekty geometrii wyniósł 1 min 8 s i był wyraźnie niższy niż w PostgreSQL, lecz istotnie wyższy niż w DuckDB.

Kolejnym etapem preprocessingu była transformacja danych do metrycznego układu odniesienia EPSG:2180, stanowiącego wariant podstawowy w dalszych eksperymentach empirycznych. W środowisku Python/GeoPandas transformacja zbioru geo_hex była realizowana partiami w celu zapewnienia stabilności wykonania. W przypadku MongoDB oraz BigQuery GIS etap ten nie był wykonywany ze względu na brak wsparcia dla

metrycznych, planarnych układów odniesienia. Zestawienie czasów transformacji danych z układu EPSG:4326 do EPSG:2180 przedstawiono w tabeli 5.2.1d.

Tabela 5.2.1d Czasy transformacji danych z EPSG:4326 do EPSG:2180

Silnik	dat_poi	geo_polska	osm_roads	geo_hex	Łącznie
PostgreSQL	7.65s	5.37s	14.82s	27m 2s	27m 29s
DuckDB	0.13s	1.73s	0.54s	11.34s	13.74s
GeoPandas	0.52s	1.02s	1.80s	3m 7s	3m 10s
MongoDB	n/d				n/d
BigQuery	n/d				n/d

Źródło: opracowanie własne

Analiza łącznych czasów transformacji danych do metrycznego układu odniesienia EPSG:2180 wskazuje na bardzo duże zróżnicowanie kosztów tego etapu pomiędzy analizowanymi silnikami obliczeniowymi. Najkrótszy łączny czas transformacji uzyskano w środowisku DuckDB (13,74 s), natomiast najwyższy w przypadku PostgreSQL z rozszerzeniem PostGIS (27 min 29 s), co było związane z kosztami reprojekcji bardzo dużego zbioru geo_hex. W środowisku Python/GeoPandas łączny czas transformacji wyniósł 3 min 10 s i był istotnie niższy niż w PostgreSQL, lecz wyraźnie wyższy niż w DuckDB.

Następnym etapem preprocessingu była budowa indeksów przestrzennych w układzie EPSG:2180, realizowana we wszystkich silnikach oferujących jawne mechanizmy indeksowania danych geometrycznych. W środowisku Python/GeoPandas wykorzystano struktury sindex oraz STRtree, działające w pamięci operacyjnej aplikacji. MongoDB oraz BigQuery GIS nie umożliwiają wykonywania operacji w metrycznym układzie odniesienia EPSG:2180, w związku z czym etap ten nie został w nich zrealizowany. Zestawienie czasów budowy indeksów przedstawiono w tabeli 5.2.1e.

Tabela 5.2.1e Czasy budowy indeksów przestrzennych dla danych typu geometry (EPSG:2180)

Silnik	dat_poi	geo_polska	osm_roads	geo_hex	Łącznie
PostgreSQL	1.86s	0.01s	1.37s	1m 21s	1m 24s
DuckDB	0.16s	0.05s	0.19s	11.42s	11.82s
GeoPandas sindex / STRtree	0.200930s / 0.488094s	0.000951s / 0.001410s	0.261986s / 0.574377s	41.02s / 20.53s	41.31s / 21.50s
MongoDB	n/d				n/d
BigQuery	n/d				n/d

Źródło: opracowanie własne

Analiza czasów budowy indeksów przestrzennych w metrycznym układzie odniesienia EPSG:2180 wskazuje na bardzo duże zróżnicowanie kosztów tego etapu pomiędzy analizowanymi silnikami obliczeniowymi. Najkrótszy czas budowy indeksów uzyskano w środowisku DuckDB (11,84 s), natomiast najwyższy w przypadku PostgreSQL z rozszerzeniem PostGIS (1 min 24 s), co było związane z indeksowaniem bardzo dużego zbioru geo_hex. W środowisku Python/GeoPandas zastosowanie struktury STRtree pozwoliło na skrócenie czasu budowy indeksów do 20,53 s w porównaniu do 41,02 s uzyskanych przy wykorzystaniu mechanizmu sindex.

W kolejnym etapie przeprowadzono budowę indeksów przestrzennych dla danych typu geography w układzie EPSG:4326, jako uzupełnienie indeksowania wykonanego wcześniej w metrycznym układzie odniesienia EPSG:2180, który stanowi wariant podstawowy w niniejszej pracy. Etap ten był realizowany wyłącznie w silnikach obsługujących geodezyjny model danych przestrzennych.

W PostgreSQL z rozszerzeniem PostGIS indeksy dla danych typu geography utworzono obok indeksów planarnych, w celu umożliwienia porównań pomiędzy modelem planarnym i geodezyjnym w obrębie jednego środowiska wykonawczego. Analogiczny etap zrealizowano w MongoDB, gdzie indeksy geodezyjne stanowią podstawowy mechanizm realizacji zapytań geoprzestrzennych. W środowisku BigQuery GIS etap ten nie był wykonywany, ponieważ mechanizmy indeksowania przestrzennego są w pełni zarządzane przez platformę i nie podlegają jawnej konfiguracji przez użytkownika.

Zestawienie czasów budowy indeksów przestrzennych dla danych typu geography (EPSG:4326) przedstawiono w tabeli 5.2.1f.

Tabela 5.2.1f Czasy budowy indeksów przestrzennych dla danych typu geography (EPSG:4326)

Silnik	dat_poi	geo_polska	osm_roads	geo_hex	Łącznie
PostgreSQL	3.78s	0.01s	4.25s	9m 28s	9m 36s
DuckDB	n/d				n/d
GeoPandas	n/d				n/d
MongoDB	2.44s	24.66s	19.29s	8m 35s	9m 31s
BigQuery	n/d				n/d

Źródło: opracowanie własne

Analiza czasów budowy indeksów przestrzennych dla danych typu geography w układzie EPSG:4326 wskazuje na porównywalny koszt tego etapu w środowiskach PostgreSQL z rozszerzeniem PostGIS oraz MongoDB. Łączny czas budowy indeksów wyniósł odpowiednio 9 min 36 s w PostgreSQL oraz 9 min 31 s w MongoDB, przy czym w obu przypadkach dominującym składnikiem czasowym było indeksowanie bardzo dużego zbioru geo_hex.

Ostatnim etapem preprocessingu był eksport danych do plików CSV w układzie EPSG:4326. Etap ten został zrealizowany wyłącznie w celu umożliwienia porównań pomocniczych oraz analizy kosztu operacji wejścia–wyjścia (I/O) i nie miał wpływu na przebieg ani wyniki właściwych eksperymentów empirycznych. W środowisku BigQuery zbiory osm_roads oraz geo_hex zostały wyeksportowane do wielu plików wynikowych ze względu na ograniczenia platformy dotyczące maksymalnego rozmiaru pojedynczego pliku. Zestawienie czasów eksportu przedstawiono w tabeli 5.2.1g.

Tabela 5.2.1g Czasy eksportu danych do plików CSV w układzie EPSG:4326

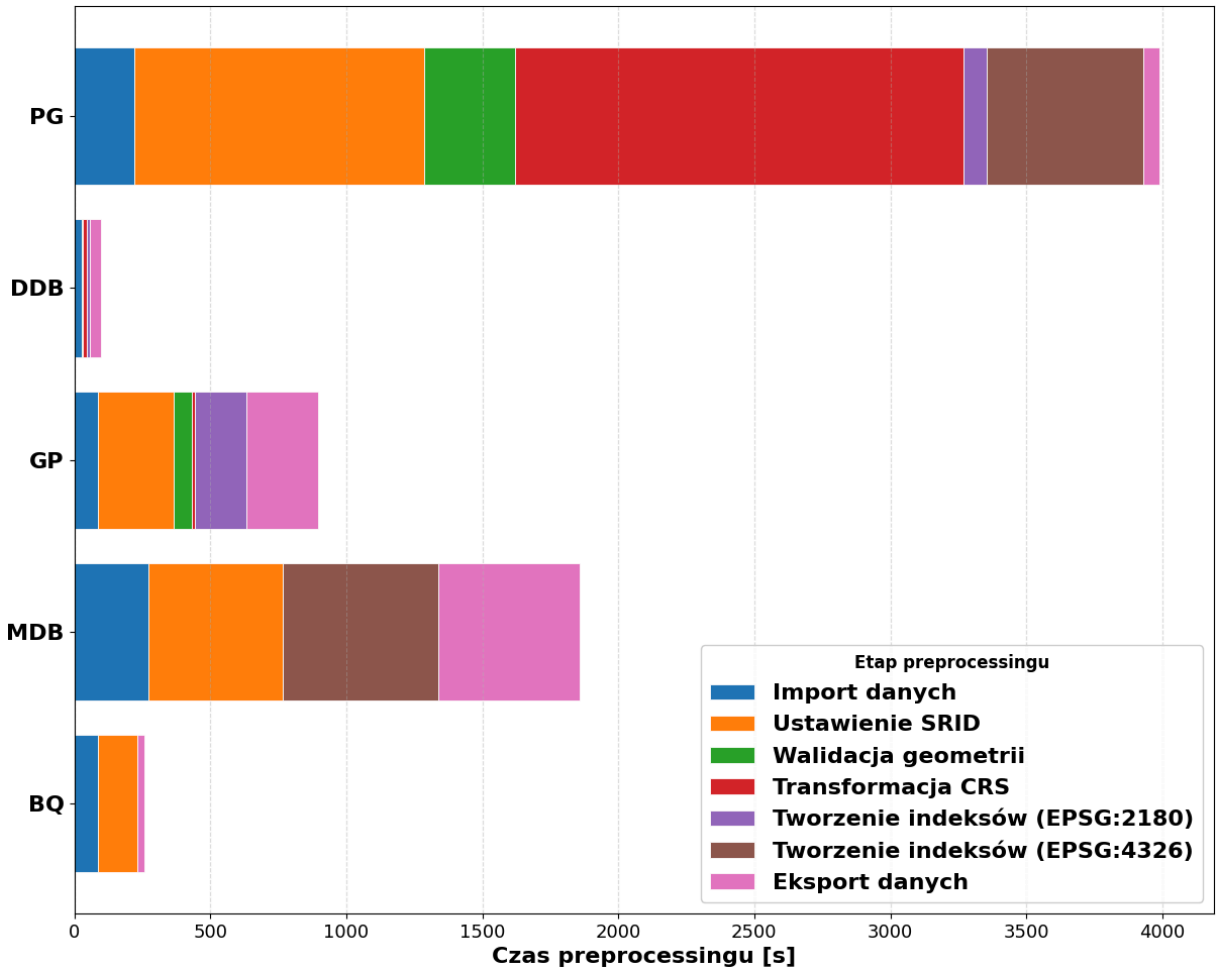
Silnik	dat_poi	geo_polska	osm_roads	geo_hex	Łącznie
PostgreSQL	0.49s	0.74s	0.92s	59.12s	1m 1s
DuckDB	0.10s	1.36s	0.37s	37.33s	39.19s
GeoPandas	2.34s	3.48s	6.72s	4m 10s	4m 22s
MongoDB	6.42s	9.75s	17.17s	8m 7s	8m 40s
BigQuery	4.01s (4.27s)	12.44s (19.76s)	3.50s (27.59s)	6.15s (12m 6s)	26.10s (12m 58s)

Źródło: opracowanie własne

Analiza łącznych czasów eksportu danych do plików CSV wskazuje na istotne różnice pomiędzy analizowanymi silnikami obliczeniowymi w zakresie kosztu operacji wejścia–wyjścia. Najkrótszy łączny czas eksportu uzyskano w środowisku BigQuery GIS, dla którego rzeczywisty czas wykonania operacji (*elapsed time*) wyniósł 26,10 s, natomiast najwyższy w przypadku MongoDB (8 min 40 s). Relatywnie niski koszt eksportu odnotowano również w środowisku DuckDB (39,19 s), podczas gdy Python/GeoPandas oraz PostgreSQL charakteryzowały się wyraźnie wyższymi czasami eksportu, odpowiednio 4 min 23 s oraz 1 min 1 s. Wyniki te pokazują, że koszt operacji I/O może istotnie różnić się pomiędzy silnikami, mimo że etap ten nie wpływa bezpośrednio na przebieg właściwych eksperymentów empirycznych.

5.2.2 Obserwacje empiryczne preprocessingu

Źródło: opracowanie własne



Rys. 5.2.2 Struktura czasowa preprocessingu danych przestrzennych w analizowanych silnikach obliczeniowych

Na podstawie wyników zaprezentowanych w tabelach 5.2.1a–5.2.1g oraz rysunku 5.2.2 można sformułować następujące obserwacje empiryczne dotyczące preprocessingu danych przestrzennych.

Największy udział w całkowitym czasie preprocessingu mają etapy realizowane na największych zbiorach danych, w szczególności na zbiorze geo_hex. Zjawisko to obserwowano we wszystkich analizowanych silnikach, niezależnie od ich architektury oraz modelu danych przestrzennych, i wynika to bezpośrednio ze skali przetwarzanych danych.

Istotny koszt czasowy generują również etapy związane z transformacją układów odniesienia przestrzennego oraz budową indeksów przestrzennych. Jest to szczególnie zauważalne w scenariuszach wymagających reprojekcji danych do układu EPSG:2180 oraz tworzenia indeksów dla bardzo dużej liczby obiektów geometrycznych.

Pomiędzy analizowanymi silnikami obliczeniowymi obserwowane są wyraźne różnice zarówno w czasie realizacji poszczególnych etapów preprocessingu, jak i w zakresie dostępności tych operacji. W części środowisk niektóre etapy nie były realizowane lub wymagały zastosowania rozwiązań alternatywnych, co zostało jawnie uwzględnione w raportowanych wynikach.

Preprocessing ma charakter etapu jednorazowego, po którym dane mogą być wielokrotnie wykorzystywane w kolejnych eksperymentach empirycznych bez ponoszenia dodatkowego kosztu przygotowawczego. Z tego względu czasy preprocessingu nie są uwzględniane w analizie czasów wykonania zapytań przestrzennych prezentowanych w dalszej części rozdziału.

5.3 Eksperymenty odległościowe (E1–E4)

W ramach niniejszej sekcji zaprezentowano wyniki pomiarów czasowych dla poszczególnych eksperymentów odległościowych oraz obserwacje empiryczne wynikające bezpośrednio z uzyskanych danych.

5.3.1 Wyniki pomiarów czasowych (E1–E4)

Eksperyment E1 – wyszukiwanie najbliższego obiektu POI

Celem eksperymentu E1 było wyznaczenie najbliższego obiektu typu POI względem zadanego punktu referencyjnego.

Tabela 5.3.1a Czasy wykonania eksperymentu E1

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	0.000079s (0.004677s)
PostgreSQL (geography, EPSG:4326)	0.645122s (0.076588s)
DuckDB (geometry, EPSG:2180)	0.247589s (1.616065s)
GeoPandas (geometry, EPSG:2180)	0.000510s
MongoDB (geography, EPSG:4326)	0.002s (0.018s)
BigQuery GIS (geography, EPSG:4326)	0.859s (0.945s)

Źródło: opracowanie własne

Uwaga: W wariancie PostgreSQL (EPSG:4326, geography) operator <-> zwraca dystans geodezyjny w metrach, lecz nie realizuje wyszukiwania typu KNN z wykorzystaniem indeksu GiST.

Analiza czasów wykonania eksperymentu E1 wskazuje na bardzo duże zróżnicowanie wydajności pomiędzy analizowanymi silnikami obliczeniowymi. Najkrótszy czas wykonania uzyskano w środowisku PostgreSQL w wariancie geometrycznym EPSG:2180 (0,000079 s), natomiast najwyższy w środowisku BigQuery GIS (0,859 s). Wariant PostgreSQL oparty na modelu geodezyjnym EPSG:4326 charakteryzował się wyraźnie wyższym czasem wykonania (0,645 s) w porównaniu do wariantu planarnego. Relatywnie niskie czasy uzyskano również w środowisku MongoDB (0,002 s), natomiast DuckDB oraz GeoPandas osiągnęły wyniki pośrednie.

Eksperyment E2 – wyszukiwanie najbliższego POI z podziałem na kategorie

Celem eksperymentu E2 było wyznaczenie najbliższego punktu POI osobno dla każdej kategorii obiektów względem zadanego punktu referencyjnego.

Tabela 5.3.1b Czasy wykonania eksperymentu E2

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	0.066276s (0.310543s)
PostgreSQL (geography, EPSG:4326)	0.088455s (0.539498s)
DuckDB (geometry, EPSG:2180)	0.373611s (1.803703s)
GeoPandas (geometry, EPSG:2180)	0.023774s
MongoDB (geography, EPSG:4326)	0.688s (1.393s)
BigQuery GIS (geography, EPSG:4326)	3.11s (7.93s)

Źródło: opracowanie własne

W eksperymencie E2, obejmującym wyszukiwanie najbliższego obiektu POI dla poszczególnych kategorii, najkrótszy czas wykonania uzyskano w PostgreSQL w wariancie geometrycznym EPSG:2180 (0,066 s). Wariant geodezyjny PostgreSQL oraz GeoPandas osiągnęły porównywalne, nieco wyższe czasy (0,088 s i 0,024 s). Najwyższe czasy wykonania odnotowano w BigQuery GIS (3,11 s) oraz MongoDB (0,688 s).

Eksperyment E3 – zapytania promieniowe dla rosnących odległości

Celem eksperymentu E3 było obliczenie liczby punktów POI znajdujących się w kolejnych promieniach od punktu referencyjnego (od 50 m do 100 000 m), z rozbiciem na kategorie obiektów.

Tabela 5.3.1c Czasy wykonania eksperymentu E3

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	0.576775s (1.675269s)
PostgreSQL (geography, EPSG:4326)	1.123263s (2.2449145s)
DuckDB (geometry, EPSG:2180)	0.345324s (1.861000s)
GeoPandas (geometry, EPSG:2180)	0.081114s
MongoDB (geography, EPSG:4326)	3.925s (4.662s)
BigQuery GIS (geography, EPSG:4326)	2.27s (21.37s)

Źródło: opracowanie własne

Analiza wyników eksperymentu E3 pokazuje, że zapytania promieniowe realizowane w metrycznym układzie odniesienia EPSG:2180 charakteryzują się niższymi czasami wykonania w porównaniu do wariantów geodezyjnych EPSG:4326. Najkrótszy czas wykonania uzyskano w środowisku GeoPandas (0,081 s), natomiast najwyższy w środowisku MongoDB (3,925 s). Wariant PostgreSQL oparty na modelu geodezyjnym osiągnął czas niemal dwukrotnie wyższy niż wariant planarny, co potwierdza istotny wpływ modelu danych przestrzennych na koszt zapytań odległościowych.

Eksperyment E4 – odległość punktów POI do granic jednostek administracyjnych

Celem eksperymentu E4 było obliczenie odległości punktów POI do granic jednostek administracyjnych (gmin, powiatów, województw oraz granicy państwa) dla rosnącej liczby obiektów wejściowych.

Tabela 5.3.1d Czasy wykonania eksperymentu E4

Silnik	limit 1000	limit 10000	limit 100000	limit 500000	brak limitu
PG:2180	2.64s (3.27s)	27.14s	4m 43s	22m 52s	38m 27s
PG:4326	42.17s	7m 10s	1h 7m 34s	> 1h 30m	
DuckDB	3.18s (3.37s)	30.12s	4m 59s	6m 30s	9m 48s
GeoPandas	2.45s	24.67s	4m 8s	20m 23s	37m 42s
MongoDB	n/d				
BigQuery GIS	16.05s (10m 53s)	1m 55s (1h 44m)	17m 1s (14h 36m)	przerwane (limit zasobów)	

Źródło: opracowanie własne

Wyniki eksperymentu E4 wskazują na bardzo silną zależność czasu wykonania od liczby przetwarzanych punktów POI. Wraz ze wzrostem limitu danych wejściowych obserwowano gwałtowny wzrost czasu realizacji zapytań we wszystkich środowiskach, w których wykonanie tego scenariusza było możliwe. Najniższe czasy wykonania dla dużych wolumenów danych uzyskano w środowisku DuckDB, natomiast wariant PostgreSQL oparty na układzie EPSG:4326 charakteryzował się najwyższym kosztem obliczeniowym. Należy przy tym zaznaczyć, że w wariantach EPSG:4326 zastosowano podejście mieszane, w którym operacje topologiczne realizowano na typie geometry, natomiast obliczenia odległości wykonywano na typie geography, co zwiększało złożoność zapytań. W środowisku BigQuery GIS czasy rzeczywiste wykonania zapytań rosły wraz z liczbą punktów wejściowych, jednak dla największych zakresów danych część wariantów eksperymentu nie została ukończona z powodu przekroczenia limitów zasobów obliczeniowych, co ograniczyło możliwość pełnego porównania.

5.3.2 Obserwacje empiryczne (E1–E4)

Na podstawie wyników zaprezentowanych w tabelach 5.3.1a–5.3.1d można sformułować następujące obserwacje empiryczne.

W eksperymentach E1–E3 różnice czasów wykonania pomiędzy analizowanymi silnikami obliczeniowymi oraz pomiędzy wariantami opartymi na modelu planarnym i geodezyjnym są zauważalne w większości analizowanych scenariuszy. Warianty wykorzystujące układ odniesienia EPSG:4326 charakteryzują się wyraźnie wyższymi czasami wykonania w porównaniu do wariantów metrycznych EPSG:2180, niezależnie od zastosowanego silnika.

W eksperymencie E4 zaobserwowano silny wzrost czasu wykonania wraz ze wzrostem liczby punktów POI. Zjawisko to występuje we wszystkich środowiskach, w których realizacja tego scenariusza była możliwa, i nasila się szczególnie dla dużych wolumenów danych wejściowych. Należy przy tym zauważyć, że eksperyment E4 różni się charakterem od eksperymentów E1–E3, ponieważ łączy operacje topologiczne na granicach obiektów powierzchniowych z obliczeniami odległościowymi, co skutkuje wyraźnie większym kosztem obliczeniowym.

Dla bardzo dużych zbiorów danych część środowisk nie była w stanie zakończyć obliczeń w ramach dostępnych limitów zasobów, co skutkowało przerwaniem zapytań lub brakiem wyników dla wybranych wariantów eksperymentalnych.

Nie wszystkie analizowane silniki oferują możliwość realizacji zapytań odległościowych wymagających relacji typu punkt → granica jednostki administracyjnej, co znalazło odzwierciedlenie w braku wyników dla części scenariuszy eksperymentalnych.

5.4 Eksperymenty geometryczne i topologiczne (E5–E8)

W ramach niniejszej sekcji zaprezentowano wyniki pomiarów czasowych dla eksperymentów geometrycznych i topologicznych oraz obserwacje empiryczne wynikające bezpośrednio z uzyskanych danych.

5.4.1 Wyniki pomiarów czasowych (E5–E8)

Eksperyment E5 – obliczenie podstawowych cech geometrycznych

Celem eksperymentu E5 było obliczenie trzech podstawowych cech geometrycznych (powierzchnia, długość granicy oraz centroid) dla wszystkich jednostek administracyjnych w Polsce.

Tabela 5.4.1a Czasy wykonania eksperymentu E5

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	0.180211s (0.847841s)
PostgreSQL (geography, EPSG:4326)	10.76s
DuckDB (geometry, EPSG:2180)	0.098349s (0.119671s)
GeoPandas (geometry, EPSG:2180)	0.073568s
MongoDB (geography, EPSG:4326)	n/d
BigQuery GIS (geography, EPSG:4326)	8.03s (14.72s)

Źródło: opracowanie własne

Uwaga:

W środowisku MongoDB eksperyment E5 nie był realizowany, ponieważ system ten nie oferuje wsparcia dla podstawowych operacji geometrycznych wymaganych w tym scenariuszu, takich jak obliczanie pola powierzchni (ST_Area), długości granicy (ST_Perimeter) oraz wyznaczanie centroidu (ST_Centroid). Brak tych funkcji uniemożliwia wykonanie obliczeń cech geometrycznych w przyjętym modelu eksperymentalnym.

Analiza czasów wykonania eksperymentu E5 wskazuje na istotne różnice wydajności pomiędzy analizowanymi silnikami obliczeniowymi. Najkrótszy czas wykonania uzyskano w środowisku GeoPandas (0,07 s) oraz DuckDB (0,09 s), natomiast najwyższe czasy odnotowano w wariantach opartych na układzie EPSG:4326, w szczególności w środowisku PostgreSQL (9,76 s) oraz BigQuery GIS (8,03 s). Wariant PostgreSQL wykorzystujący model

planarny EPSG:2180 charakteryzował się znacząco niższym kosztem obliczeniowym (0,18 s), co potwierdza wpływ modelu danych przestrzennych na wydajność obliczeń cech geometrycznych. Należy przy tym zaznaczyć, że w wariantach EPSG:4326 zastosowano podejście mieszane, w którym geometria obiektów była przetwarzana w modelu geometry, natomiast obliczenia metryczne realizowano na typie geography, co wynikało z ograniczeń funkcjonalnych modelu geodezyjnego.

Eksperyment E6 – przecięcia buforów gmin z granicami województw

Celem eksperymentu E6 było przecięcie obszarów gmin powiększonych o 5 km z granicami województw oraz pomiar kosztu operacji ST_Intersection na dużych zbiorach danych.

Tabela 5.4.1b Czasy wykonania eksperymentu E6

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	2m 33s
PostgreSQL (geography, EPSG:4326)	2m 46s
DuckDB (geometry, EPSG:2180)	35.10s
GeoPandas (geometry, EPSG:2180)	7.05s
MongoDB (geography, EPSG:4326)	n/d
BigQuery GIS (geography, EPSG:4326)	39m 48s (3h 17m)

Źródło: opracowanie własne

Uwaga:

W środowisku MongoDB eksperyment nie był realizowany ze względu na brak wsparcia dla operacji buforowania geometrii.

Wyniki eksperymentu E6 pokazują wyraźne zróżnicowanie kosztu realizacji operacji przecięcia geometrii pomiędzy analizowanymi środowiskami. Najkrótszy czas wykonania uzyskano w środowisku GeoPandas (7,05 s) oraz DuckDB (35,10 s), natomiast najwyższe czasy odnotowano w środowiskach bazodanowych, w szczególności w PostgreSQL oraz BigQuery GIS. Należy przy tym zaznaczyć, że w wariancie PostgreSQL obliczenia realizowane były w modelu mieszanym, obejmującym operacje topologiczne na typie geometry oraz obliczenia metryczne wykonywane na typie geography. Pomimo tego różnice pomiędzy wariantami PostgreSQL opartymi na układach EPSG:2180 i EPSG:4326 pozostają

relatywnie niewielkie, co wskazuje, że w tym scenariuszu dominującym czynnikiem kosztowym jest złożoność operacji topologicznej, a nie sam wybór modelu odniesienia przestrzennego.

Eksperyment E7 – liczba punktów POI w jednostkach administracyjnych

Celem eksperymentu E7 było obliczenie liczby punktów POI znajdujących się w granicach jednostek administracyjnych na czterech poziomach hierarchii: kraj, województwo, powiat oraz gmina.

Tabela 5.4.1c Czasy wykonania eksperymentu E7

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	8.29s (12.69s)
PostgreSQL (geography, EPSG:4326)	11.90s (16.84s)
DuckDB (geometry, EPSG:2180)	2m 8s
GeoPandas (geometry, EPSG:2180)	3.81s
MongoDB (geography, EPSG:4326)	2m 10s
BigQuery GIS (geography, EPSG:4326)	18.39s (5h 41m)

Źródło: opracowanie własne

Analiza wyników eksperymentu E7 wskazuje, że zapytania typu point-in-polygon realizowane w metrycznym układzie odniesienia EPSG:2180 charakteryzują się niższymi czasami wykonania w porównaniu do wariantów geodezyjnych EPSG:4326. Najkrótszy czas wykonania uzyskano w środowisku GeoPandas (3,81 s), natomiast najwyższe czasy odnotowano w środowiskach DuckDB oraz MongoDB, gdzie realizacja zapytań wymagała przetwarzania bardzo dużych zbiorów punktowych. Wariant BigQuery GIS osiągnął czas pośredni (18,39 s), przy czym towarzyszył mu wysoki łączny nakład pracy obliczeniowej (*slot time consumed*), wynikający ze specyfiki rozproszonego środowiska wykonawczego.

Eksperyment E8 – diagram Voronoi i przecięcia z granicami województw

Celem eksperymentu E8 było zmierzenie wydajności generowania diagramu Voronoi dla rosnącej liczby punktów POI oraz ocena kosztu przecięć komórek Voronoi z granicami województw.

Tabela 5.4.1d Czasy wykonania eksperymentu E8

Silnik	limit 1000	limit 10000	limit 100000	limit 500000	brak limitu
PG:2180	2.29s (3.51s)	19.58s	3m 5s	16m 31s	28m 56s
PG:4326	2.76s (4.27s)	20.64s	3m 22s	17m 5s	30m 21s
DuckDB	n/d				
GeoPandas	2.56s	20.58s	3m 18s	16m 58s	29m 49s
MongoDB	n/d				
BigQuery GIS	n/d				

Źródło: opracowanie własne

Uwaga:

W eksperymencie generowania diagramu Voronoi w środowisku PostgreSQL z rozszerzeniem PostGIS, przy wykorzystaniu układu EPSG:4326, geometria komórek Voronoi była tworzona w jednostkach kątowych (stopnie), ponieważ funkcja generowania diagramu Voronoi obsługuje wyłącznie typ geometry. Obliczenia pól powierzchni realizowano następnie w jednostkach metrycznych poprzez rzutowanie wynikowych geometrii do typu geography. W pozostałych eksperymentach opartych na układzie EPSG:4326 operacje metryczne wykonywano bezpośrednio na typie geography, bez etapu pośredniego tworzenia geometrii w jednostkach kątowych.

Wyniki eksperymentu E8 wskazują na wyraźny wzrost czasu wykonania wraz ze wzrostem liczby punktów wejściowych wykorzystywanych do generowania diagramu Voronoi. Zależność ta jest obserwowana zarówno w wariancie planarnym EPSG:2180, jak i w wariancie opartym na EPSG:4326. Dla mniejszych limitów liczby punktów czasy wykonania pozostają porównywalne pomiędzy wariantami układów odniesienia, natomiast wraz ze wzrostem skali danych obserwowany jest gwałtowny wzrost kosztu obliczeniowego, szczególnie widoczny dla limitów rzędu setek tysięcy punktów. Należy przy tym zaznaczyć, że w wariancie EPSG:4326 zastosowano podejście mieszane, w którym geometria komórek Voronoi była generowana w modelu geometry, natomiast obliczenia metryczne realizowano po rzutowaniu wynikowych obiektów do typu geography. Brak możliwości realizacji eksperymentu E8 w środowiskach DuckDB, MongoDB oraz BigQuery GIS istotnie ogranicza zakres porównania i wskazuje na różnice w zakresie wsparcia zaawansowanych operacji geometrycznych pomiędzy analizowanymi silnikami.

5.4.2 Obserwacje empiryczne (E5–E8)

Na podstawie wyników zaprezentowanych w tabelach 5.4.1a–5.4.1d można sformułować następujące obserwacje empiryczne dotyczące eksperymentów geometrycznych i topologicznych.

Eksperymenty E5–E8 charakteryzują się wyraźnie wyższymi czasami wykonania w porównaniu do zapytań odległościowych analizowanych w poprzedniej sekcji. Zjawisko to obserwowane jest we wszystkich środowiskach, w których realizacja tych scenariuszy była możliwa, i dotyczy zarówno wariantów planarnych, jak i geodezyjnych.

Pomiędzy analizowanymi silnikami obliczeniowymi, a także pomiędzy wariantami opartymi na modelu planarnym i geodezyjnym, występują zauważalne różnice czasów wykonania w większości scenariuszy eksperymentalnych. Różnice te są szczególnie widoczne w eksperymentach obejmujących przetwarzanie dużych zbiorów danych lub realizację złożonych operacji geometrycznych i topologicznych.

W eksperymentach wymagających operacji geometrycznych i topologicznych nie wszystkie silniki oferują pełne wsparcie funkcjonalne, co skutkuje brakiem wyników dla części scenariuszy. Zjawisko to dotyczy w szczególności obliczeń cech geometrycznych, operacji buforowania oraz generowania diagramów Voronoi i zostało bezpośrednio odzwierciedlone w zestawieniach wyników.

Wraz ze wzrostem liczby obiektów wejściowych obserwowany jest istotny wzrost czasu wykonania, szczególnie widoczny w eksperymencie E8. Zależność ta występuje we wszystkich środowiskach, w których realizacja tego scenariusza była możliwa, i nasila się wraz ze skalą przetwarzanych danych.

5.5 Eksperymenty liniowe (E9–E12)

W ramach niniejszej sekcji zaprezentowano wyniki pomiarów czasowych dla eksperymentów liniowych oraz obserwacje empiryczne wynikające bezpośrednio z uzyskanych danych.

5.5.1. Wyniki pomiarów czasowych (E9–E12)

Eksperyment E9 – średnia długość odcinków dróg według kategorii highway

Celem eksperymentu E9 było obliczenie średniej długości odcinków dróg dla każdej kategorii highway na podstawie danych liniowych.

Tabela 5.5.1a Czasy wykonania eksperymentu E9

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	0.234706s (1.154425s)
PostgreSQL (geography, EPSG:4326)	1.714069s (2.815183s)
DuckDB (geometry, EPSG:2180)	0.053063s (0.466650s)
GeoPandas (geometry, EPSG:2180)	0.098023s
MongoDB (geography, EPSG:4326)	n/d
BigQuery GIS (geography, EPSG:4326)	1.77s (6.79s)

Źródło: opracowanie własne

Uwaga:

W środowisku MongoDB eksperyment E9 nie został zrealizowany ze względu na brak operacji odpowiadającej funkcji obliczania długości geometrii liniowej (np. ST_Length) w przyjętym modelu eksperymentalnym.

Analiza czasów wykonania eksperymentu E9 wskazuje na wyraźne różnice wydajności pomiędzy analizowanymi silnikami obliczeniowymi. Najkrótszy czas wykonania uzyskano w środowisku DuckDB (0,05 s) oraz GeoPandas (0,09 s), natomiast najwyższe czasy odnotowano w wariantach geodezyjnych opartych na EPSG:4326, w szczególności w środowisku PostgreSQL (1,71 s) oraz BigQuery GIS (1,77 s). Wariant PostgreSQL wykorzystujący model planarny EPSG:2180 charakteryzował się znacząco niższym kosztem obliczeniowym (0,23 s), co potwierdza wpływ modelu danych przestrzennych na wydajność obliczeń długości obiektów liniowych.

Eksperyment E10 – wyznaczenie najbliższej drogi dla punktów POI

Celem eksperymentu E10 było wyznaczenie najbliższego odcinka drogi dla każdego punktu POI z wykorzystaniem zapytań przestrzennych typu nearest neighbor w relacji punkt–linia.

Tabela 5.5.1b Czasy wykonania eksperymentu E10

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	44.73s
PostgreSQL (geography, EPSG:4326)	6m 30s
DuckDB (geometry, EPSG:2180)	LIMIT 2500 metrów: 4m 51s LIMIT 5000 metrów: 30 m 12s
GeoPandas (geometry, EPSG:2180)	52.28s
MongoDB (geography, EPSG:4326)	26m 24s
BigQuery GIS (geography, EPSG:4326)	LIMIT 2500 metrów: 48.65s (12h 8m) LIMIT 5000 metrów: przekroczenie limitu zasobów

Źródło: opracowanie własne

Uwaga:

W środowisku DuckDB w eksperymencie E10 zastosowano dodatkowe ograniczenia maksymalnego promienia wyszukiwania (LIMIT 2500 m oraz LIMIT 5000 m). Bez wprowadzenia takiego ograniczenia czas wykonania zapytań rósł gwałtownie wraz ze wzrostem liczby analizowanych obiektów liniowych, co uniemożliwiało zakończenie obliczeń w rozsądnym czasie.

W środowisku MongoDB eksperyment został zrealizowany z wykorzystaniem etapu agregacji $geoNear (indeks 2dsphere), wskazującego geometrię liniową jako zbiór referencyjny. Operacja ta była wykonywana iteracyjnie dla kolejnych punktów POI, co odpowiada typowemu wzorcowi aplikacyjnemu w systemach dokumentowych. W przeciwieństwie do silników relacyjnych i analitycznych, MongoDB nie oferuje zbiorczego, jednorazowego złączenia przestrzennego typu point–line nearest neighbor, a raportowany czas obejmuje również narzut iteracji po danych.

W środowisku BigQuery GIS część wariantów eksperymentu została przerwana z powodu przekroczenia limitów zasobów obliczeniowych w modelu rozliczeń on-demand, co uniemożliwiło realizację zapytań dla większych promieni wyszukiwania.*

Wyniki eksperymentu E10 pokazują bardzo wysoki koszt realizacji zapytań typu nearest neighbor w relacji punkt–linia, szczególnie dla dużych zbiorów danych liniowych. Najkrótszy czas wykonania bez dodatkowych ograniczeń uzyskano w środowisku PostgreSQL w wariancie planarnym EPSG:2180 (44,73 s) oraz w środowisku GeoPandas (52,28 s). W środowisku DuckDB oraz BigQuery GIS konieczne było wprowadzenie dodatkowych ograniczeń promienia wyszukiwania w celu zakończenia obliczeń w rozsądnym czasie. Wariant geodezyjny PostgreSQL (EPSG:4326) oraz środowisko MongoDB charakteryzowały się wyraźnie wyższymi czasami wykonania, co wskazuje na istotny koszt relacji punkt–linia realizowanej na dużych zbiorach danych.

Eksperyment E11 – najdłuższy odcinek drogi według kategorii highway

Celem eksperymentu E11 było wyznaczenie najdłuższego odcinka drogi dla każdej kategorii highway na podstawie danych liniowych.

Tabela 5.5.1c Czasy wykonania eksperymentu E11

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	0.65s (1.45s)
PostgreSQL (geography, EPSG:4326)	2.08s (3.11s)
DuckDB (geometry, EPSG:2180)	0.17s (0.48s)
GeoPandas (geometry, EPSG:2180)	0.10s
MongoDB (geography, EPSG:4326)	n/d
BigQuery GIS (geography, EPSG:4326)	2.35s (10.47s)

Źródło: opracowanie własne

Uwaga:

W środowisku MongoDB eksperyment E11 nie był realizowany ze względu na brak wsparcia dla operacji obliczania długości geometrii liniowych (brak odpowiednika funkcji ST_Length).

Analiza wyników eksperymentu E11 wskazuje, że obliczenia długości obiektów liniowych realizowane w metrycznym układzie odniesienia EPSG:2180 charakteryzują się niższymi czasami wykonania w porównaniu do wariantów geodezyjnych EPSG:4326. Najkrótszy czas wykonania uzyskano w środowisku GeoPandas (0,10 s) oraz DuckDB (0,17 s), natomiast najwyższe czasy odnotowano w środowisku BigQuery GIS (2,35 s) oraz w

wariancie PostgreSQL opartym na modelu geodezyjnym (2,08 s). Różnice te potwierdzają wpływ modelu odniesienia przestrzennego na koszt obliczeń długości obiektów liniowych.

Eksperyment E12 – łączna długość dróg w promieniu 500 m od punktów POI

Celem eksperymentu E12 było obliczenie łącznej długości odcinków dróg znajdujących się w promieniu 500 m od rosnącej liczby punktów POI.

Tabela 5.5.1d Czasy wykonania eksperymentu E12

Silnik	limit 1000	limit 10000	limit 100000	limit 500000	brak limitu
PG:2180	0.38s (1.21s)	3.87s	39.21s	3m 24s	6m 12s
PG:4326	1.80s (2.79s)	15.83s	2m 50s	14m 53s	27m 7s
DuckDB	0.06s (0.34s)	0.11s	0.54s	2.64s	4.96s
GeoPandas	0.50s	4.70s	45.99s	3m 53s	7m 2s
MongoDB	n/d				
BigQuery GIS	2.03s (5m 46s)	2.21s (11m 12s)	3.64s (45m 4s)	11.84s (3h 35m)	17.25s (5h 22m)

Źródło: opracowanie własne

Uwaga:

W środowisku MongoDB eksperyment E12 nie był możliwy do wykonania ze względu na brak wsparcia dla operacji dystansowych w relacji punkt–linia.

Wyniki eksperymentu E12 wskazują na wyraźny wzrost czasu wykonania wraz ze wzrostem liczby punktów POI, dla których realizowane było obliczenie łącznej długości dróg w zadanym promieniu. Zależność ta obserwowana jest we wszystkich środowiskach, w których wykonanie eksperymentu było możliwe, przy czym tempo wzrostu czasu wykonania różni się istotnie pomiędzy analizowanymi silnikami. Najlepszą skalowalność w badanym zakresie wykazało środowisko DuckDB, natomiast warianty oparte na modelu geodezyjnym EPSG:4326 charakteryzowały się wyraźnie wyższym kosztem obliczeniowym. W środowisku BigQuery GIS czasy rzeczywiste wykonania zapytań pozostawały relatywnie niskie (rzędu kilkunastu sekund), jednak towarzyszył im bardzo wysoki łączny nakład pracy obliczeniowej (*slot time consumed*), który istotnie wzrastał wraz z wielkością danych wejściowych.

5.5.2. Obserwacje empiryczne (E9–E12)

Na podstawie wyników zaprezentowanych w tabelach 5.5.1a–5.5.1d można sformułować następujące obserwacje empiryczne.

W eksperymentach E9–E12 zaobserwowano wyraźny wzrost czasu wykonania wraz ze wzrostem liczby obiektów wejściowych, szczególnie w scenariuszach obejmujących relacje przestrzenne typu punkt–linia oraz agregacje długości odcinków dróg w zadanych promieniach.

Pomiędzy analizowanymi silnikami obliczeniowymi widoczne są istotne różnice czasów wykonania poszczególnych eksperymentów, a także różnice pomiędzy wariantami opartymi na układach odniesienia EPSG:2180 i EPSG:4326. Różnice te występują we wszystkich eksperymentach liniowych i nasilają się wraz ze wzrostem złożoności zapytań oraz wolumenu danych.

Nie wszystkie analizowane środowiska umożliwiały realizację pełnego zestawu eksperymentów liniowych. Brak wsparcia dla wybranych operacji geometrycznych lub relacji przestrzennych skutkował brakiem wyników dla części scenariuszy, co zostało jawnie uwzględnione w zestawieniach wyników.

W eksperymentach E10 oraz E12, obejmujących najbardziej złożone zapytania oraz największe zbiory danych, odnotowano przypadki przerwania zapytań wynikające z ograniczeń zasobów obliczeniowych w niektórych środowiskach. Zjawisko to dotyczyło wyłącznie części wariantów eksperymentalnych i zostało bezpośrednio odzwierciedlone w raportowanych wynikach.

5.6 Eksperymenty agregacyjne (E13–E16)

W ramach niniejszej sekcji zaprezentowano wyniki pomiarów czasowych dla eksperymentów agregacyjnych oraz obserwacje empiryczne wynikające bezpośrednio z uzyskanych danych.

5.6.1. Wyniki pomiarów czasowych (E13–E16)

Eksperyment E13 – agregacja heksagonów w obrębie województw (UnaryUnion)

Celem eksperymentu E13 było wykonanie operacji agregacji geometrycznej heksagonów przypisanych do województw z wykorzystaniem operacji ST_UnaryUnion, przy limicie 1 000 000 obiektów wejściowych uporządkowanych według identyfikatora.

Tabela 5.6.1a Czasy wykonania eksperymentu E13

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	1m 15s
PostgreSQL (geography, EPSG:4326)	1m 28s
DuckDB (geometry, EPSG:2180)	n/d
GeoPandas (geometry, EPSG:2180)	1m 27s
MongoDB (geography, EPSG:4326)	n/d
BigQuery GIS (geography, EPSG:4326)	10m 29s (1h 44m)

Źródło: opracowanie własne

Uwaga:

W środowiskach MongoDB oraz DuckDB eksperyment E13 nie został zrealizowany, ponieważ silniki te nie oferują operacji odpowiadających funkcjom ST_Collect oraz ST_UnaryUnion, wymaganych do wykonania agregacji geometrii wielokątowych.

Analiza czasów wykonania eksperymentu E13 wskazuje na wysoki koszt agregacji geometrycznej dużej liczby obiektów poligonowych. Najkrótszy czas wykonania uzyskano w środowisku PostgreSQL w wariancie planarnym EPSG:2180 (1 min 15 s), natomiast wariant geodezyjny EPSG:4326 charakteryzował się nieco wyższym czasem wykonania (1 min 28 s). Zbliżony wynik uzyskano w środowisku GeoPandas (1 min 27 s). Najwyższy koszt obliczeniowy odnotowano w środowisku BigQuery GIS, gdzie czas rzeczywisty wykonania

zapytania wyniósł ponad 10 minut, przy bardzo wysokim łącznym nakładzie pracy obliczeniowej.

Eksperyment E14 – liczba punktów POI w heksagonach

Celem eksperymentu E14 było obliczenie liczby punktów POI znajdujących się w obrębie poszczególnych heksagonów, co odpowiada typowemu scenariuszowi agregacji punktów w regularnych jednostkach przestrzennych.

Tabela 5.6.1b Czasy wykonania eksperymentu E14

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	7m 17s
PostgreSQL (geography, EPSG:4326)	7m 25s
DuckDB (geometry, EPSG:2180)	2.27s (5.58s)
GeoPandas (geometry, EPSG:2180)	3m 58s
MongoDB (geography, EPSG:4326)	LIMIT 1,000,000 heksagonów: 21m 30s BEZ LIMITU: > 1h 30m (przerwanie wykonania)
BigQuery GIS (geography, EPSG:4326)	LIMIT 100,000 heksagonów: 11m 8s (8d 21h) BEZ LIMITU: przekroczenie limitów zasobów

Źródło: opracowanie własne

Uwaga:

W środowiskach MongoDB oraz BigQuery GIS pełna realizacja eksperymentu E14 bez ograniczeń liczby heksagonów nie była możliwa ze względu na przekroczenie dostępnych zasobów obliczeniowych. W związku z tym część pomiarów została wykonana dla wariantów limitowanych, obejmujących jedynie podzbiory danych wejściowych. Zastosowanie limitów stanowi istotny kontekst interpretacyjny przy porównywaniu wyników pomiędzy silnikami, ponieważ raportowane czasy nie zawsze odnoszą się do pełnego zbioru danych, lecz do zakresów wymuszonych ograniczeniami środowiska wykonawczego.

Wyniki eksperymentu E14 charakteryzują się bardzo dużym zróżnicowaniem czasów wykonania pomiędzy analizowanymi silnikami. Szczególnie niskie czasy uzyskane w środowisku DuckDB należy wiązać z odmiennym modelem wykonania zapytań, opartym na przetwarzaniu wektorowym w pamięci operacyjnej oraz braku narzutu związanego z transakcyjnością i zarządzaniem pamięcią masową, typowego dla systemów bazodanowych. W tego typu scenariuszach agregacyjnych podejście to sprzyja uzyskiwaniu bardzo niskich

czasów wykonania. Z kolei w środowiskach MongoDB oraz BigQuery GIS pełna realizacja eksperymentu dla całego zbioru danych nie była możliwa ze względu na ograniczenia zasobowe, co ogranicza zakres bezpośrednich porównań dla największych wolumenów danych.

Eksperyment E15 – łączna długość dróg w heksagonach

Celem eksperymentu E15 było obliczenie łącznej długości odcinków dróg znajdujących się w obrębie poszczególnych heksagonów, co wymaga wykonania złączenia przestrzennego w relacji linia–poligon oraz agregacji metrycznej.

Tabela 5.6.1c Czasy wykonania eksperymentu E15

Silnik	Czas wykonania
PostgreSQL (geometry, EPSG:2180)	9m 1s
PostgreSQL (geography, EPSG:4326)	11m 24s
DuckDB (geometry, EPSG:2180)	11.63s
GeoPandas (geometry, EPSG:2180)	8m 8s
MongoDB (geography, EPSG:4326)	n/d
BigQuery GIS (geography, EPSG:4326)	4.64s (1h 8m)

Źródło: opracowanie własne

Uwaga:

W środowisku MongoDB eksperyment E15 nie został zrealizowany ze względu na brak wsparcia dla obliczeń części wspólnej obiektów typu linia–poligon.

Analiza czasów wykonania eksperymentu E15 wskazuje na wysoki koszt realizacji złączeń przestrzennych w relacji linia–poligon połączonych z agregacją metryczną. Najkrótszy czas wykonania uzyskano w środowisku DuckDB (11,63 s), natomiast środowiska PostgreSQL oraz GeoPandas charakteryzowały się wyraźnie wyższymi czasami wykonania, sięgającymi od kilku do kilkunastu minut. Wariant PostgreSQL oparty na układzie EPSG:4326 wykazał dodatkowy wzrost kosztu obliczeniowego w porównaniu do wariantu planarnego. Należy przy tym zaznaczyć, że w wariantach EPSG:4326 zastosowano podejście mieszane, w którym relacje przestrzenne linia–poligon realizowano na typie geometry, natomiast obliczenia metryczne długości wykonywano na typie geography. W środowisku BigQuery GIS czas rzeczywisty wykonania zapytania był relatywnie niski, jednak

towarzyszył mu bardzo wysoki łączny nakład pracy obliczeniowej, co ogranicza praktyczną skalowalność tego podejścia.

Eksperyment E16 – złączenie przestrzenne heksagonów z województwami

Celem eksperymentu E16 było wykonanie złączenia przestrzennego heksagonów z poligonami województw dla rosnącej liczby obiektów wejściowych, co odpowiada klasycznemu scenariuszowi złączenia przestrzennego w relacji poligon–poligon. W każdym wariancie heksagony były wybierane w sposób deterministyczny, z zastosowaniem sortowania według identyfikatora obiektu.

Tabela 5.6.1d Czasy wykonania eksperymentu E16

Silnik	limit 1000	limit 10000	limit 100000	limit 500000	limit 1000000
PG:2180	0.29s (0.49s)	10.06s	1m 57s	9m 42s	17m 54s
PG:4326	0.30s (0.51s)	11.42s	2m 4s	10m 15s	18m 46s
DuckDB	0.63s (2.34s)	16.30s	3m 29s	16m 38s	32m 4s
GeoPandas	0.22s	6.79s	1m 16s	6m 36s	13m 23s
MongoDB	n/d				
BigQuery GIS	2.44s (59.40s)	15.75s (10m 42s)	2m 26s (2h 4s)	10m 17s (13h 48m)	14m 17s (2d 4h)

Źródło: opracowanie własne

Uwaga:

W środowisku MongoDB eksperyment E16 nie został zrealizowany ze względu na brak wsparcia dla obliczeń relacji przestrzennych typu poligon–poligon oraz brak możliwości wyznaczania powierzchni przecięcia obiektów geometrycznych.

Wyniki eksperymentu E16 potwierdzają, że złączenia przestrzenne typu poligon–poligon charakteryzują się bardzo niekorzystną skalowalnością wraz ze wzrostem liczby obiektów wejściowych, niezależnie od zastosowanego silnika obliczeniowego. Wraz ze zwiększaniem liczby analizowanych heksagonów obserwowano systematyczny wzrost czasu wykonania zapytań we wszystkich środowiskach, w których realizacja eksperymentu była możliwa. Najniższe czasy wykonania dla dużych wolumenów danych uzyskano w środowisku GeoPandas, natomiast DuckDB oraz PostgreSQL osiągały wyraźnie wyższe czasy wykonania wraz ze wzrostem limitu danych wejściowych. Warianty PostgreSQL oparte

na układzie EPSG:4326 charakteryzowały się dodatkowym wzrostem kosztu obliczeniowego w porównaniu do wariantów planarnych. Należy przy tym zaznaczyć, że w wariantach EPSG:4326 zastosowano podejście mieszane, w którym relacje przestrzenne poligon–poligon realizowano na typie geometry, natomiast obliczenia pól powierzchni wykonywano na typie geography. W środowisku BigQuery GIS czasy rzeczywiste wykonania zapytań pozostawały relatywnie niskie, jednak towarzyszył im bardzo wysoki łączny nakład pracy obliczeniowej.

5.6.2. Obserwacje empiryczne (E13–E16)

Na podstawie wyników zaprezentowanych w tabelach 5.6.1a–5.6.1d można sformułować następujące obserwacje empiryczne dotyczące eksperymentów agregacyjnych.

Eksperymenty agregacyjne realizowane na siatkach heksagonalnych należą do najbardziej kosztownych obliczeniowo scenariuszy spośród wszystkich przeprowadzonych badań. W szczególności operacje wymagające złączeń przestrzennych oraz agregacji bardzo dużej liczby obiektów geometrycznych (E13, E15, E16) charakteryzują się długimi czasami wykonania, nawet przy zastosowaniu indeksów przestrzennych.

Pomiędzy analizowanymi silnikami obliczeniowymi obserwowane są istotne różnice zarówno w czasie realizacji zapytań, jak i w zakresie dostępności wymaganych operacji przestrzennych. W części środowisk (MongoDB, BigQuery GIS) pełna realizacja wybranych eksperymentów nie była możliwa lub wymagała zastosowania limitów liczby obiektów wejściowych, co znalazło bezpośrednie odzwierciedlenie w raportowanych wynikach czasowych.

Wraz ze wzrostem liczby heksagonów obserwowany jest systematyczny wzrost czasu wykonania zapytań we wszystkich silnikach, które umożliwiały realizację tych scenariuszy. Zależność ta występuje niezależnie od zastosowanego modelu danych przestrzennych i stanowi wspólną cechę wszystkich środowisk obsługujących agregacje przestrzenne na dużą skalę.

5.7 Podsumowanie wyników badań empirycznych

W niniejszym rozdziale przedstawiono wyniki badań empirycznych obejmujących etap preprocessingu danych przestrzennych oraz zestaw szesnastu eksperymentów obliczeniowych realizowanych w różnych silnikach przetwarzania danych przestrzennych. Badania przeprowadzono z wykorzystaniem jednolitych zbiorów danych oraz spójnych scenariuszy

eksperymentalnych, co umożliwiło bezpośrednie porównanie uzyskanych wyników czasowych.

Na podstawie przeprowadzonych pomiarów stwierdzono, że preprocessing danych stanowi istotny element całego procesu badawczego, szczególnie w przypadku bardzo dużych zbiorów danych przestrzennych. Największy koszt czasowy generowały operacje wykonywane na zbiorze heksagonów, w tym transformacje układów odniesienia przestrzennego, walidacja geometrii oraz budowa indeksów przestrzennych. Etap ten ma jednak charakter jednorazowy i nie wpływa bezpośrednio na czasy wykonania zapytań analizowanych w dalszej części badań.

Eksperymenty odległościowe (E1–E4) wykazały zauważalne różnice czasów wykonania pomiędzy analizowanymi silnikami obliczeniowymi, a także pomiędzy wariantami opartymi na modelu planarnym i geodezyjnym. Wraz ze wzrostem liczby obiektów wejściowych obserwowano systematyczny wzrost czasu wykonania zapytań, a w części środowisk wystąpiły ograniczenia uniemożliwiające realizację najbardziej złożonych scenariuszy.

W eksperymentach geometrycznych i topologicznych (E5–E8) odnotowano wyraźnie wyższą złożoność obliczeniową w porównaniu do zapytań odległościowych. Nie wszystkie analizowane silniki oferowały pełne wsparcie dla operacji takich jak buforowanie, przecięcia czy generowanie diagramów Voronoi, co znalazło odzwierciedlenie w zakresie możliwych do wykonania eksperymentów.

Eksperymenty liniowe (E9–E12) wykazały istotne zróżnicowanie czasów wykonania zapytań w przypadku operacji opartych na relacjach punkt–linia oraz agregacji obiektów liniowych. W scenariuszach obejmujących bardzo duże wolumeny danych oraz realizowanych na rozległych obszarach przestrzennych w części analizowanych środowisk odnotowano przerwanie wykonania zapytań lub konieczność wprowadzenia dodatkowych ograniczeń obliczeniowych.

Najbardziej kosztowne obliczeniowo okazały się eksperymenty agregacyjne realizowane na siatkach heksagonalnych (E13–E16). Operacje takie jak złączenia przestrzenne, agregacje geometryczne oraz obliczenia wykonywane na bardzo dużej liczbie obiektów prowadziły do znaczącego wzrostu czasu wykonania zapytań.

W trakcie analizy wyników zwracanych przez zapytania przestrzenne zaobserwowano, że w części środowisk obliczeniowych wartości wynikowe nie były w pełni tożsame z rezultatami uzyskanymi w środowisku referencyjnym PostgreSQL z rozszerzeniem PostGIS (wariant geometry, EPSG:2180). Różnice te miały charakter marginalny i dotyczyły

wybranych scenariuszy obliczeniowych, w szczególności operacji odległościowych realizowanych w modelu geodezyjnym lub w środowiskach wykorzystujących odmienne implementacje obliczeń przestrzennych. W żadnym z analizowanych przypadków nie prowadziły one jednak do zmiany jakościowej interpretacji wyników ani do odmiennych wniosków analitycznych.

Przedstawione wyniki empiryczne stanowią podstawę do sformułowania wniosków porównawczych oraz dalszej interpretacji dotyczącej wydajności i możliwości analizowanych silników obliczeniowych, które zostaną zaprezentowane w kolejnym rozdziale pracy.

6. Wnioski końcowe i kierunki dalszych badań

Niniejszy rozdział stanowi syntetyczne podsumowanie przeprowadzonych badań empirycznych oraz prezentuje wnioski wynikające z uzyskanych rezultatów. W przeciwieństwie do Rozdziału 5, w którym przedstawiono wyniki pomiarów oraz obserwacje empiryczne bez ich interpretacji przyczynowej, w niniejszym rozdziale dokonano ich analizy porównawczej oraz uogólnienia w kontekście wydajności, możliwości i ograniczeń analizowanych silników obliczeniowych.

Na podstawie wyników uzyskanych w preprocessingu danych przestrzennych oraz w scenariuszach eksperymentalnych obejmujących zapytania odległościowe, operacje geometryczne i topologiczne, analizy liniowe oraz agregacje przestrzenne sformułowano wnioski dotyczące wpływu modelu danych przestrzennych, skali przetwarzanych zbiorów oraz architektury środowiska wykonawczego na efektywność obliczeń. W rozdziale wskazano również praktyczne konsekwencje uzyskanych wyników, w szczególności z punktu widzenia zastosowań związanych z inżynierią cech w zadaniach uczenia maszynowego, a także omówiono ograniczenia przeprowadzonych badań oraz potencjalne kierunki ich dalszego rozwoju.

6.1 Wnioski dotyczące wydajności obliczeń przestrzennych

Na podstawie wyników badań empirycznych przedstawionych w Rozdziale 5 można sformułować wnioski dotyczące wydajności obliczeń przestrzennych w analizowanych silnikach obliczeniowych, z uwzględnieniem różnych klas operacji oraz wolumenu przetwarzanych danych.

W przypadku zapytań odległościowych oraz prostych operacji geometrycznych, realizowanych na umiarkowanych zbiorach danych, wszystkie analizowane silniki umożliwiały uzyskanie wyników w czasie akceptowalnym z punktu widzenia analiz eksploracyjnych oraz wstępnej inżynierii cech. Jednocześnie widoczne były istotne różnice pomiędzy wariantami opartymi na modelu planarnym i geodezyjnym, przy czym warianty wykorzystujące metryczne układy odniesienia charakteryzowały się krótszym czasem wykonania w większości analizowanych scenariuszy.

Wraz ze wzrostem złożoności zapytań oraz liczby obiektów wejściowych obserwowany był systematyczny wzrost czasu wykonania obliczeń we wszystkich środowiskach. Zjawisko to było szczególnie widoczne w eksperymentach obejmujących operacje topologiczne,

złączenia przestrzenne oraz agregacje geometryczne realizowane na dużych zbiorach danych. W tych przypadkach istotnym czynnikiem różnicującym wyniki okazywała się nie tylko wydajność samego silnika, lecz także charakter zastosowanego modelu danych przestrzennych oraz sposób realizacji operacji złożonych, obejmujący m.in. wykorzystanie indeksów przestrzennych, strategię planowania zapytań oraz liczbę etapów obliczeniowych wymaganych do przetworzenia geometrii.

Największe różnice wydajnościowe pomiędzy analizowanymi silnikami ujawniły się w eksperymentach wymagających przetwarzania bardzo dużej liczby obiektów geometrycznych, w szczególności w scenariuszach opartych na siatkach heksagonalnych. W tego typu zadaniach część środowisk nie była w stanie zakończyć obliczeń w ramach dostępnych zasobów obliczeniowych lub wymagała wprowadzenia dodatkowych ograniczeń liczby obiektów wejściowych. W praktyce oznacza to, że obok samego czasu wykonania istotnym kryterium porównawczym staje się również wykonalność danego scenariusza obliczeniowego w ramach danego środowiska wykonawczego.

Z przeprowadzonych badań wynika również, że wydajność obliczeń przestrzennych jest w istotnym stopniu determinowana przez dostępność oraz efektywność mechanizmów indeksowania przestrzennego. W analizowanych silnikach widoczne były różnice pomiędzy środowiskami oferującymi jawne, konfigurowalne indeksy przestrzenne a rozwiązaniami, w których indeksowanie miało charakter ograniczony lub było w pełni zarządzane przez platformę. Różnice te przekładały się na odmienne czasy realizacji zapytań przestrzennych, szczególnie w scenariuszach obejmujących duże zbiory danych.

Podsumowując, uzyskane wyniki wskazują, że wraz ze wzrostem skali danych oraz złożoności operacji przestrzennych różnice wydajnościowe pomiędzy analizowanymi silnikami obliczeniowymi stają się coraz bardziej wyraźne. Dobór środowiska obliczeniowego ma zatem kluczowe znaczenie w przypadku zaawansowanych analiz przestrzennych realizowanych na dużych zbiorach danych i powinien być uzależniony od charakteru planowanych operacji oraz oczekiwanej skali przetwarzania.

Z punktu widzenia zastosowań związanych z inżynierią cech w zadaniach uczenia maszynowego oznacza to, że wydajność obliczeń przestrzennych staje się czynnikiem krytycznym już na etapie przygotowania danych, a nie dopiero w fazie treningu modeli.

6.2 Wnioski dotyczące modeli przestrzeni: geometry vs geography

Na podstawie przeprowadzonych badań empirycznych można sformułować wnioski dotyczące wpływu wyboru modelu przestrzeni na wydajność obliczeń, zakres funkcjonalny oraz złożoność zapytań przestrzennych. Analiza obejmowała warianty planarne oparte na typie geometry w metrycznym układzie odniesienia EPSG:2180 oraz warianty geodezyjne oparte na typie geography w układzie EPSG:4326.

Uzyskane wyniki jednoznacznie wskazują, że w scenariuszach wymagających intensywnych obliczeń metrycznych wariant planarny w układzie EPSG:2180 charakteryzuje się krótszym czasem wykonania zapytań w porównaniu do wariantu geodezyjnego. Różnice te narastają wraz ze wzrostem liczby obiektów wejściowych oraz złożoności operacji, co było szczególnie widoczne w eksperymentach obejmujących złączenia przestrzenne, agregacje geometryczne oraz operacje realizowane na bardzo dużych zbiorach danych, takich jak siatki heksagonalne.

Model geodezyjny geography, oparty na obliczeniach realizowanych na powierzchni elipsoidy odniesienia, umożliwia bezpośrednie wykonywanie obliczeń metrycznych w układzie EPSG:4326 bez konieczności reprojekcji danych. Badania wykazały jednak, że wiąże się to z wyższym kosztem obliczeniowym oraz, w części przypadków, z ograniczeniami funkcjonalnymi w zakresie dostępnych operacji geometrycznych i topologicznych.

W analizowanych eksperymentach zaobserwowano również, że w środowiskach wykorzystujących układ EPSG:4326 część scenariuszy wymagała stosowania podejścia mieszanego, polegającego na wykonywaniu operacji topologicznych na typie geometry oraz obliczeń metrycznych na typie geography. Takie rozwiązanie zwiększało złożoność zapytań, utrudniało ich optymalizację oraz prowadziło do wzrostu czasu wykonania w porównaniu do wariantów realizowanych wyłącznie w modelu planarnym w układzie EPSG:2180.

Z przeprowadzonych badań wynika ponadto, że nie wszystkie analizowane silniki obliczeniowe oferują równoważne wsparcie dla obu modeli przestrzeni. W części środowisk obsługa ograniczona jest wyłącznie do modelu geodezyjnego w układzie EPSG:4326, natomiast w innych brak jest wsparcia dla typu geography, co wymusza stosowanie reprojekcji danych do układów metrycznych w celu uzyskania poprawnych wyników obliczeń odległości i powierzchni.

Podsumowując, wybór modelu przestrzeni ma istotny wpływ zarówno na wydajność obliczeń, jak i na sposób realizacji zapytań przestrzennych. Wariant planarny w metrycznym

układzie odniesienia sprzyja wydajnym i skalowalnym obliczeniom na dużych zbiorach danych, natomiast wariant geodezyjny zapewnia poprawność metryczną w układach geograficznych kosztem zwiększonego narzutu obliczeniowego oraz ograniczeń funkcjonalnych. Wyniki badań potwierdzają zasadność świadomego i kontekstowego doboru modelu przestrzeni w zależności od charakteru analizowanego problemu obliczeniowego.

6.3 Wnioski dotyczące doboru silnika do zastosowań praktycznych

Na podstawie przeprowadzonych badań empirycznych możliwe jest sformułowanie wniosków dotyczących przydatności analizowanych silników obliczeniowych w kontekście zastosowań praktycznych, w szczególności związanych z inżynierią cech przestrzennych. Zastosowania tego typu charakteryzują się specyficznymi wymaganiami, obejmującymi konieczność przetwarzania dużych wolumenów danych, realizację powtarzalnych zapytań agregacyjnych i odległościowych, a także potrzebę zachowania kompromisu pomiędzy wydajnością obliczeń, dokładnością wyników oraz zakresem dostępnych operacji przestrzennych.

Wyniki badań wskazują, że największą przydatność w zadaniach inżynierii cech na dużych zbiorach danych przestrzennych wykazują silniki umożliwiające realizację obliczeń w metrycznym, planarnym układzie odniesienia, z wykorzystaniem wydajnych mechanizmów indeksowania oraz zoptymalizowanych implementacji operacji przestrzennych. W tym kontekście szczególnie korzystne okazały się środowiska PostgreSQL z rozszerzeniem PostGIS (wariant geometry, EPSG:2180) oraz DuckDB z rozszerzeniem Spatial, które w większości eksperymentów oferowały stabilne czasy wykonania oraz dobrą skalowalność wraz ze wzrostem liczby obiektów wejściowych.

Silnik PostgreSQL/PostGIS charakteryzuje się najszerszym zakresem funkcjonalnym, obejmującym zarówno operacje odległościowe, topologiczne, jak i złożone agregacje geometryczne. W połączeniu z możliwością stosowania indeksów przestrzennych GiST oraz realizacją obliczeń w układach metrycznych środowisko to dobrze sprawdza się w scenariuszach wymagających generowania dużej liczby cech przestrzennych, takich jak liczniki obiektów w zadanych promieniach, złączenia przestrzenne czy agregacje na regularnych siatkach. Kosztem tej uniwersalności jest jednak relatywnie wysoki narzut preprocessingu.

DuckDB Spatial wykazał bardzo wysoką wydajność w zadaniach analitycznych typu batch, szczególnie w eksperymentach agregacyjnych oraz operacjach realizowanych w

układzie EPSG:2180. Jego zaletą jest niskie opóźnienie wykonania zapytań oraz dobra skalowalność przy przetwarzaniu dużych zbiorów danych w środowisku lokalnym. Jednocześnie brak wsparcia dla modelu geodezyjnego powoduje, że silnik ten najlepiej sprawdza się jako komponent potoku obliczeniowego do masowego generowania cech, a nie jako uniwersalna platforma analiz przestrzennych.

Środowisko Python/GeoPandas okazało się szczególnie przydatne w fazie eksploracji danych, prototypowania cech oraz walidacji wyników, oferując bardzo niskie czasy wykonania dla mniejszych zbiorów danych oraz dużą elastyczność implementacyjną. Jednakże wraz ze wzrostem wolumenu danych obserwowano istotny spadek wydajności oraz ograniczenia wynikające z przetwarzania w pamięci operacyjnej, co czyni to środowisko mniej odpowiednim do pełnoskalowych zadań inżynierii cech na bardzo dużych zbiorach danych.

BigQuery GIS, pomimo relatywnie niskich czasów rzeczywistych wykonania zapytań (elapsed time) w części eksperymentów, charakteryzuje się odmiennym profilem kosztu obliczeniowego wynikającym z architektury rozproszonej oraz sposobu alokacji zasobów w środowisku chmurowym. Wysoki łączny nakład pracy obliczeniowej nie stanowi w tym przypadku bezpośredniego ograniczenia funkcjonalnego, lecz odzwierciedla równoległy charakter przetwarzania oraz skalę zasobów angażowanych do realizacji zapytań.

Z perspektywy inżynierii cech przestrzennych BigQuery GIS dobrze sprawdza się w scenariuszach wymagających jednorazowego lub okresowego przetwarzania bardzo dużych zbiorów danych. Jednocześnie brak bezpośredniej kontroli nad modelem wykonawczym zapytań oraz ograniczenia wynikające z obsługi wyłącznie geodezyjnego modelu danych przestrzennych powodują, że środowisko to ma bardziej ograniczoną rolę w porównaniu z relacyjnymi silnikami bazodanowymi, takimi jak PostgreSQL z rozszerzeniem PostGIS.

MongoDB, oparty na geodezyjnym modelu danych przestrzennych, wykazał ograniczoną przydatność w kontekście inżynierii cech, głównie ze względu na brak wsparcia dla wielu operacji geometrycznych, topologicznych oraz agregacyjnych. Choć środowisko to umożliwia realizację wybranych zapytań odległościowych i punktowych, jego funkcjonalność oraz skalowalność okazały się niewystarczające dla bardziej złożonych scenariuszy analitycznych.

Uzyskane wyniki potwierdzają, że dla masowego generowania cech przestrzennych na dużych zbiorach danych kluczowe znaczenie ma możliwość wykonywania operacji w metrycznych układach odniesienia oraz dostęp do wydajnych mechanizmów agregacji i złączeń przestrzennych. Tym samym wybór silnika do przetwarzania danych przestrzennych

na potrzeby uczenia maszynowego powinien być traktowany jako decyzja architektoniczna, uzależniona od roli danego etapu w całym potoku przetwarzania danych, a nie jako wybór jednego uniwersalnego narzędzia.

6.4 Ograniczenia przeprowadzonych badań

Przeprowadzone badania empiryczne pozwoliły na szczegółową analizę wydajności oraz zakresu funkcjonalnego wybranych silników obliczeniowych do przetwarzania danych przestrzennych. Jednocześnie należy wskazać ograniczenia, które wpływają na interpretację uzyskanych wyników. Ograniczenia te mają w przeważającej mierze charakter metodologiczny i technologiczny, a nie wynikają z błędów pomiarowych lub nieprawidłowej konstrukcji eksperymentów.

Pierwszym istotnym ograniczeniem jest zależność wyników od przyjętego zestawu scenariuszy eksperymentalnych. Choć zaprojektowane eksperymenty obejmowały szerokie spektrum operacji przestrzennych, w tym zapytania odległościowe, topologiczne, liniowe oraz agregacyjne, nie wyczerpują one wszystkich możliwych zastosowań danych przestrzennych. W szczególności badania koncentrowały się na operacjach typowych dla inżynierii cech w zadaniach uczenia maszynowego, co oznacza, że uzyskane wnioski mogą nie być w pełni reprezentatywne dla innych klas analiz, takich jak symulacje przestrzenne czy analizy czasowo-przestrzenne.

Kolejnym ograniczeniem jest nierównomierny zakres wsparcia funkcjonalnego analizowanych silników obliczeniowych. W części środowisk niektóre operacje przestrzenne nie mogły zostać zrealizowane ze względu na brak odpowiednich funkcji lub ograniczenia architektoniczne, co skutkowało koniecznością pominięcia wybranych wariantów eksperymentalnych lub zastosowania limitów liczby obiektów wejściowych. Ograniczenie to zostało jawnie uwzględnione w prezentacji wyników, jednak wpływa na możliwość pełnego, bezpośredniego porównania wszystkich silników w identycznych warunkach.

Istotnym czynnikiem ograniczającym była również specyfika środowisk wykonawczych, w szczególności w przypadku silników chmurowych. W środowisku BigQuery GIS wyniki pomiarów obarczone są zmiennością wynikającą z dynamicznej alokacji zasobów w modelu rozproszonego (serverless) oraz z charakteru modelu rozliczeń on-demand, opartego na dynamicznej alokacji zasobów. Z tego względu raportowane czasy należy interpretować jako zakresy obserwowanych wartości, a nie jako deterministyczne

charakterystyki wydajnościowe porównywalne bezpośrednio z wynikami uzyskanymi w środowiskach lokalnych.

Ograniczeniem badań jest także skupienie się na dwuwymiarowych danych przestrzennych oraz wybranych układach odniesienia, w szczególności EPSG:2180 oraz EPSG:4326. Choć wybór ten był uzasadniony charakterem analizowanych zbiorów danych oraz celem pracy, uzyskane wyniki nie obejmują zagadnień związanych z przetwarzaniem danych trójwymiarowych, które mogą charakteryzować się odmiennymi właściwościami obliczeniowymi.

Należy również zauważyć, że pomiar wydajności koncentrował się wyłącznie na czasie wykonania operacji, bez szczegółowej analizy zużycia pamięci operacyjnej, obciążenia procesora czy kosztów finansowych w środowiskach chmurowych. Czynniki te mogą mieć istotne znaczenie w praktycznych zastosowaniach produkcyjnych, jednak ich uwzględnienie wykraczało poza zakres niniejszej pracy i wymagałoby odrębnej metodyki badawczej.

Podsumowując, wskazane ograniczenia nie podważają poprawności ani wartości poznawczej przeprowadzonych badań, lecz wyznaczają ramy interpretacyjne dla uzyskanych wyników. Jednocześnie stanowią one punkt wyjścia do dalszych analiz i rozszerzeń badawczych, które mogą pogłębić zrozumienie wydajności oraz możliwości przetwarzania danych przestrzennych w różnych środowiskach obliczeniowych.

6.5 Kierunki dalszych badań

Przeprowadzone badania empiryczne pozwoliły na szczegółowe porównanie wydajności oraz zakresu funkcjonalnego wybranych silników obliczeniowych do przetwarzania danych przestrzennych. Uzyskane wyniki stanowią solidną podstawę do dalszego rozwijania analiz w kilku kierunkach badawczych, które mogą pogłębić wnioski płynące z niniejszej pracy oraz rozszerzyć ich zastosowanie praktyczne.

Pierwszym naturalnym kierunkiem dalszych badań jest rozszerzenie analizy o dodatkowe miary zasobowe, takie jak zużycie pamięci operacyjnej, obciążenie procesora oraz charakterystyki wielowątkowości poszczególnych silników. W szczególności w środowiskach analitycznych i chmurowych czynniki te mogą mieć istotny wpływ na stabilność i skalowalność przetwarzania danych przestrzennych, a ich uwzględnienie umożliwiłoby pełniejszą ocenę kosztu realizacji poszczególnych scenariuszy obliczeniowych.

Kolejnym kierunkiem badań może być analiza kosztów finansowych przetwarzania danych przestrzennych w środowiskach chmurowych, z uwzględnieniem różnych modeli

rozliczeń oraz zmienności alokacji zasobów. W szczególności interesującym rozszerzeniem byłoby zestawienie czasu rzeczywistego wykonania zapytań z rzeczywistym kosztem ekonomicznym realizacji zapytań, co pozwoliłoby na ocenę opłacalności poszczególnych rozwiązań w zastosowaniach produkcyjnych.

Istotnym obszarem dalszych badań jest również integracja analiz przestrzennych z pełnym potokiem uczenia maszynowego, obejmującym nie tylko generowanie cech, lecz także trening, walidację oraz inferencję modeli predykcyjnych. Analiza taka pozwoliłaby ocenić wpływ wyboru silnika obliczeniowego nie tylko na czas preprocessingu i inżynierii cech, lecz także na całkowity czas przygotowania i aktualizacji modeli uczenia maszynowego w środowiskach produkcyjnych.

Kolejnym możliwym rozszerzeniem jest uwzględnienie dodatkowych typów danych przestrzennych, w szczególności danych rastrowych, czasowo-przestrzennych oraz trójwymiarowych. Przetwarzanie takich danych wiąże się z odmiennymi charakterystykami obliczeniowymi oraz często wymaga zastosowania innych struktur danych i algorytmów, co mogłoby istotnie wpłynąć na porównanie wydajności analizowanych silników.

Interesującym kierunkiem badań byłoby także rozszerzenie zestawu analizowanych środowisk obliczeniowych o kolejne systemy bazodanowe i analityczne, w tym rozwiązania hybrydowe lub wyspecjalizowane silniki do przetwarzania danych przestrzennych. Pozwoliłoby to na weryfikację, czy obserwowane zależności wydajnościowe mają charakter uniwersalny, czy też są specyficzne dla wybranych technologii.

Podsumowując, niniejsza praca stanowi punkt wyjścia do dalszych, pogłębionych badań nad wydajnością przetwarzania danych przestrzennych w kontekście nowoczesnych zastosowań analitycznych i uczenia maszynowego. Zaproponowane kierunki rozwoju wskazują na szerokie możliwości kontynuacji badań, zarówno w wymiarze teoretycznym, jak i aplikacyjnym, przy jednoczesnym zachowaniu spójności z praktycznymi potrzebami przetwarzania dużych zbiorów danych przestrzennych.

Bibliografia

1. Longley, P. A., Goodchild, M. F., Maguire, D. J., Rhind, D. W., *Geographic Information Science and Systems*, 4th ed., Wiley, 2015.
2. Open Geospatial Consortium (OGC), *Simple Feature Access – Part 1: Common Architecture*, OGC Standard, 2011.
3. R Spatial Community, Basic geometry types in GIS, https://r-spatial.org/, dostęp: 2026-01.
4. International Organization for Standardization (ISO), *ISO 19111:2019 – Referencing by Coordinates*.
5. International Association of Oil & Gas Producers (IOGP), *EPSG Geodetic Parameter Dataset – EPSG:4326 (WGS 84)*, https://epsg.io/, dostęp: 2026-01.
6. International Association of Oil & Gas Producers (IOGP), *EPSG Geodetic Parameter Dataset – EPSG:2180 (ETRS89 / Poland CS92)*, https://epsg.io/, dostęp: 2026-01.
7. OpenNews, *Map projections compared: Mercator, UTM, Equal Area and WGS 84*, media.opennews.org, dostęp: 2026-01.
8. PostGIS Project, *PostGIS Documentation – Geometry and Geography Types, OGC Simple Features Support*, Open Source Geospatial Foundation, dostęp: 2026-01.
9. Guttman, A., *R-Trees: A Dynamic Index Structure for Spatial Searching*, Proceedings of the ACM SIGMOD Conference, 1984.
10. PostGIS Project, *PostGIS Documentation (Manual)*, https://postgis.net/docs/, dostęp: 2026-01.
11. Shukla, D., Shivnani, C., Shah, D., *Comparing Oracle Spatial and Postgres PostGIS*, International Journal of Computer Science and Communication, vol. 7, no. 2, pp. 95–100, 2016.
12. Greener, S. G., *Analyzing Spatial Query Performance Improvements in Oracle Spatial 12c Through Cross-Vendor Comparison*, Oracle technical white paper, 2014.
13. Arbesser-Rastburg, T., *Evaluation of Spatial Database Management Systems*, Master's Thesis, University of Edinburgh, 2009.
14. Microsoft, *Spatial Data Types Overview (SQL Server)*, https://learn.microsoft.com/en-us/sql/relational-databases/spatial/spatial-data-types-overview, dostęp: 2026-01.
15. DuckDB Labs, *DuckDB – An In-Process Analytical Database*,

https://duckdb.org, dostęp: 2026-01.

16. DuckDB Labs, *DuckDB Spatial Extension – Documentation*, https://duckdb.org/docs/extensions/spatial, dostęp: 2026-01.
17. Jordahl, K. et al., *GeoPandas: Python tools for geographic data*, Journal of Open Source Software, 2018.
18. Gillies, S. et al., *Shapely: Manipulation and analysis of geometric objects*, https://shapely.readthedocs.io, dostęp: 2026-01.
19. Lovelace, R., Nowosad, J., Muenchow, J., *Geocomputation with R*, CRC Press, 2019.
20. Pebesma, E., *Simple Features for R: Standardized Support for Spatial Vector Data*, The R Journal, 2018.
21. MongoDB Inc., *MongoDB Geospatial Indexes*, https://www.mongodb.com/docs/manual/core/indexes/index-types/index-geospatial/, dostęp: 2026-01.
22. MongoDB Inc., *Geospatial Queries*, https://www.mongodb.com/docs/manual/geospatial-queries/, dostęp: 2026-01.
23. Chodorow, K., *MongoDB: The Definitive Guide*, O'Reilly Media, 2013.
24. Li, Y., Manoharan, S., *A Performance Comparison of SQL and NoSQL Databases*, IEEE International Conference on Big Data, 2013.
25. Google Cloud, *BigQuery GIS Overview*, https://cloud.google.com/bigquery/docs/gis-intro, dostęp: 2026-01.
26. Google Cloud, *Geography data type*, https://cloud.google.com/bigquery/docs/reference/standard-sql/geography_functions,dostęp: 2026-01.
27. Google Cloud, *Introduction to BigQuery pricing*, https://cloud.google.com/bigquery/pricing, dostęp: 2026-01.
28. OpenStreetMap Contributors,

OpenStreetMap,
https://www.openstreetmap.org, dostęp: 2026-01.

29. Główny Urząd Geodezji i Kartografii (GUGiK),
Państwowy Rejestr Granic (PRG),
https://www.geoportal.gov.pl/dane/panstwowy-rejestr-granic, dostęp: 2026-01.
30. Ray, S., Simion, B., Brown, A. D.,
Jackpine: A Benchmark to Evaluate Spatial Database Performance,
2011 IEEE 27th International Conference on Data Engineering (ICDE),
pp. 1139–1150, 2011.
31. Bartoszewski, D., Piórkowski, A., Lupa, M.,
The Comparison of Processing Efficiency of Spatial Data for PostGIS and MongoDB Databases,
in: Beyond Databases, Architectures and Structures. Paving the Road to Smart Data Processing and Analysis,
Communications in Computer and Information Science, vol. 1018,
Springer, pp. 291–302, 2019.
32. Hagedorn, S., Götze, P., Sattler, K.-U.,
Big Spatial Data Processing Frameworks: Feature and Performance Evaluation,
Proceedings of the 20th International Conference on Extending Database Technology (EDBT),
pp. 490–493, 2017.
33. Alam, M. M., Ray, S., Bhavsar, V. C.,
A Performance Study of Big Spatial Data Systems,
Proceedings of the 7th ACM SIGSPATIAL International Workshop on Analytics for Big Geospatial Data (BigSpatial 2018),
pp. 1–9, 2018.

Spis tabel

Tabela 2.1 Podstawowe typy geometrii przestrzennej i ich zastosowania
Tabela 2.2.3 Porównanie układów odniesienia przestrzennego
Tabela 2.3.3 Operacje przestrzenne w modelach geometry i geography
Tabela 3.1 Charakterystyka PostgreSQL z rozszerzeniem PostGIS
Tabela 3.2 Charakterystyka DuckDB z rozszerzeniem Spatial
Tabela 3.3 Charakterystyka Pythona z GeoPandas, Shapely oraz GEOS
Tabela 3.4 Charakterystyka MongoDB
Tabela 3.5 Charakterystyka Google BigQuery GIS
Tabela 3.6 Zestawienie architektur analizowanych silników obliczeniowych
Tabela 4.2 Charakterystyka zbiorów danych wykorzystanych w badaniach empirycznych
Tabela 4.3a Konfiguracja sprzętowa środowiska lokalnego
Tabela 4.3b Wersje oprogramowania wykorzystanego w badaniach
Tabela 4.6.3 Eksperymenty odległościowe i najbliższego sąsiada (E1–E4)
Tabela 4.6.4 Eksperymenty geometryczne i topologiczne (E5–E8)
Tabela 4.6.5 Eksperymenty na obiektach liniowych (E9–E12)
Tabela 4.6.6 Eksperymenty agregacyjne na siatkach heksagonalnych (E13–E16)
Tabela 5.2.1a Czasy importu danych z plików CSV z geometrią w formacie WKT
Tabela 5.2.1b Czasy przypisania układu odniesienia przestrzennego (SRID = EPSG:4326)
Tabela 5.2.1c Czasy weryfikacji i korekty geometrii
Tabela 5.2.1d Czasy transformacji danych z EPSG:4326 do EPSG:2180
Tabela 5.2.1e Czasy budowy indeksów przestrzennych dla danych typu geometry (EPSG:2180)
Tabela 5.2.1f Czasy budowy indeksów przestrzennych dla danych typu geography (EPSG:4326)
Tabela 5.2.1g Czasy eksportu danych do plików CSV w układzie EPSG:4326
Tabela 5.3.1a Czasy wykonania eksperymentu E1
Tabela 5.3.1b Czasy wykonania eksperymentu E2
Tabela 5.3.1c Czasy wykonania eksperymentu E3
Tabela 5.3.1d Czasy wykonania eksperymentu E4
Tabela 5.4.1a Czasy wykonania eksperymentu E5
Tabela 5.4.1b Czasy wykonania eksperymentu E6
Tabela 5.4.1c Czasy wykonania eksperymentu E7
Tabela 5.4.1d Czasy wykonania eksperymentu E8
Tabela 5.5.1a Czasy wykonania eksperymentu E9
Tabela 5.5.1b Czasy wykonania eksperymentu E10
Tabela 5.5.1c Czasy wykonania eksperymentu E11
Tabela 5.5.1d Czasy wykonania eksperymentu E12
Tabela 5.6.1a Czasy wykonania eksperymentu E13
Tabela 5.6.1b Czasy wykonania eksperymentu E14
Tabela 5.6.1c Czasy wykonania eksperymentu E15
Tabela 5.6.1d Czasy wykonania eksperymentu E16

Spis rysunków

Rys. 2.1 Podstawowe typy geometrii przestrzennej
Rys. 2.2.3 Porównanie wizualizacji części obszaru Stanów Zjednoczonych w różnych układach odniesienia przestrzennego (EPSG:4326, EPSG:2163, EPSG:3857, EPSG:2955)
Rys. 4.6.2 Schemat preprocessingu danych wejściowych
Rys. 5.2.2 Struktura czasowa preprocessingu danych przestrzennych w analizowanych silnikach obliczeniowych